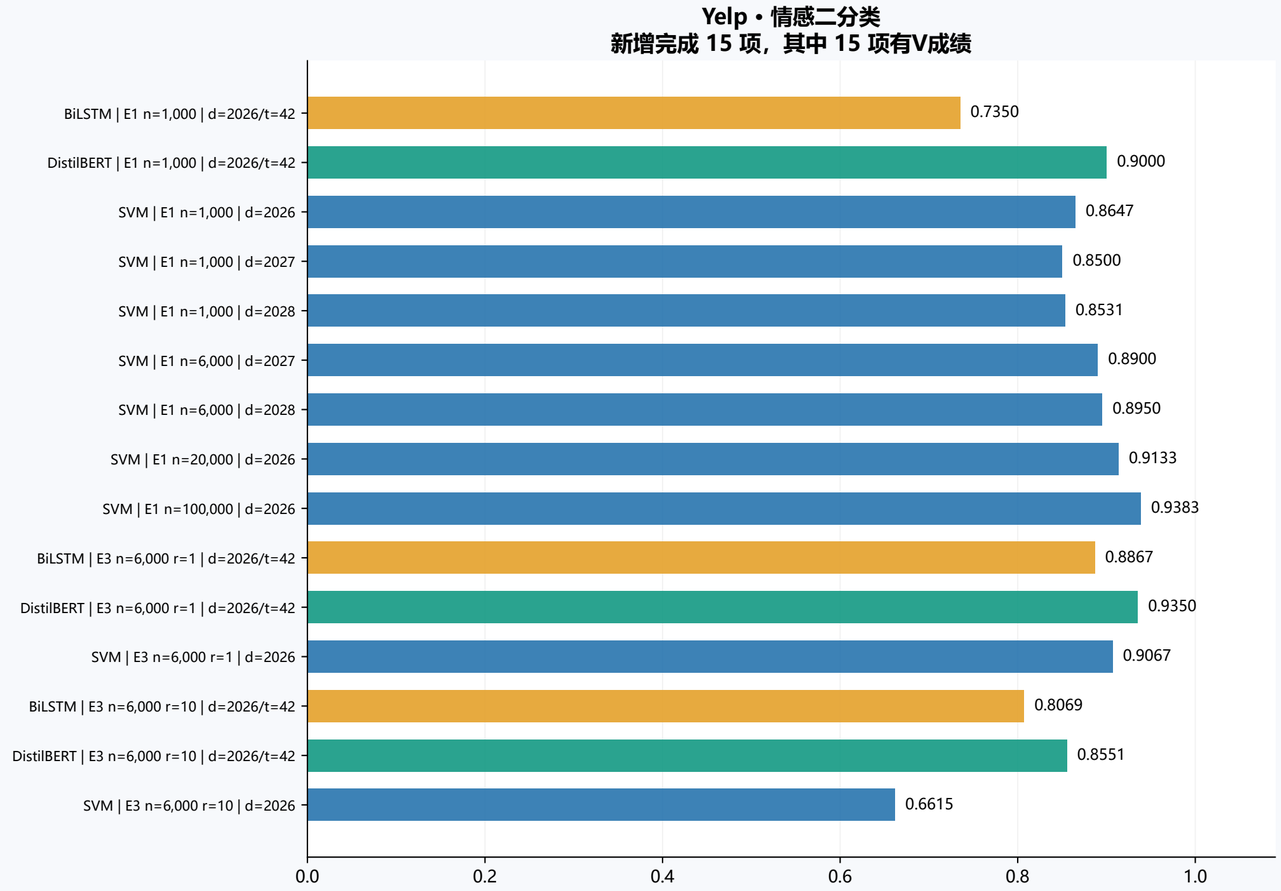
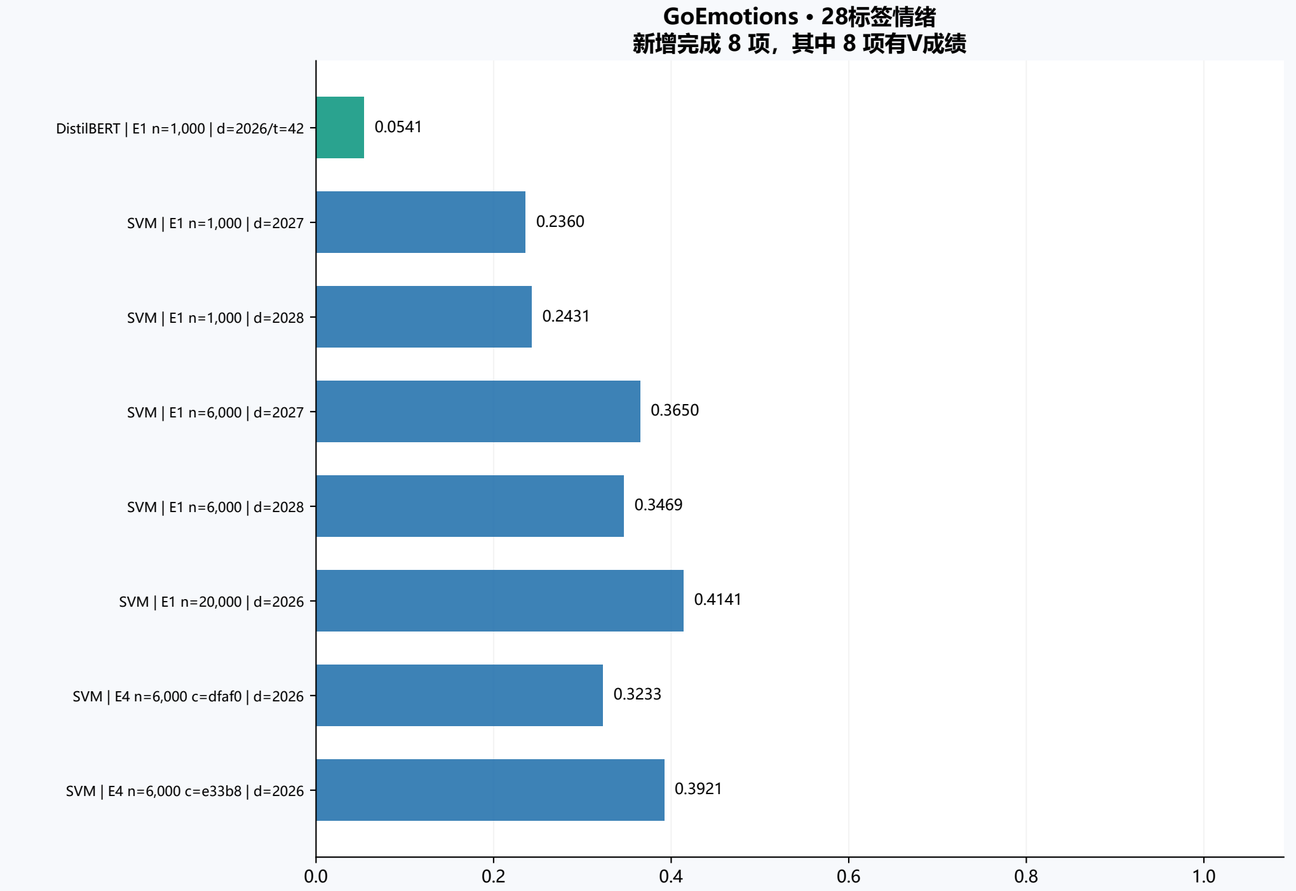
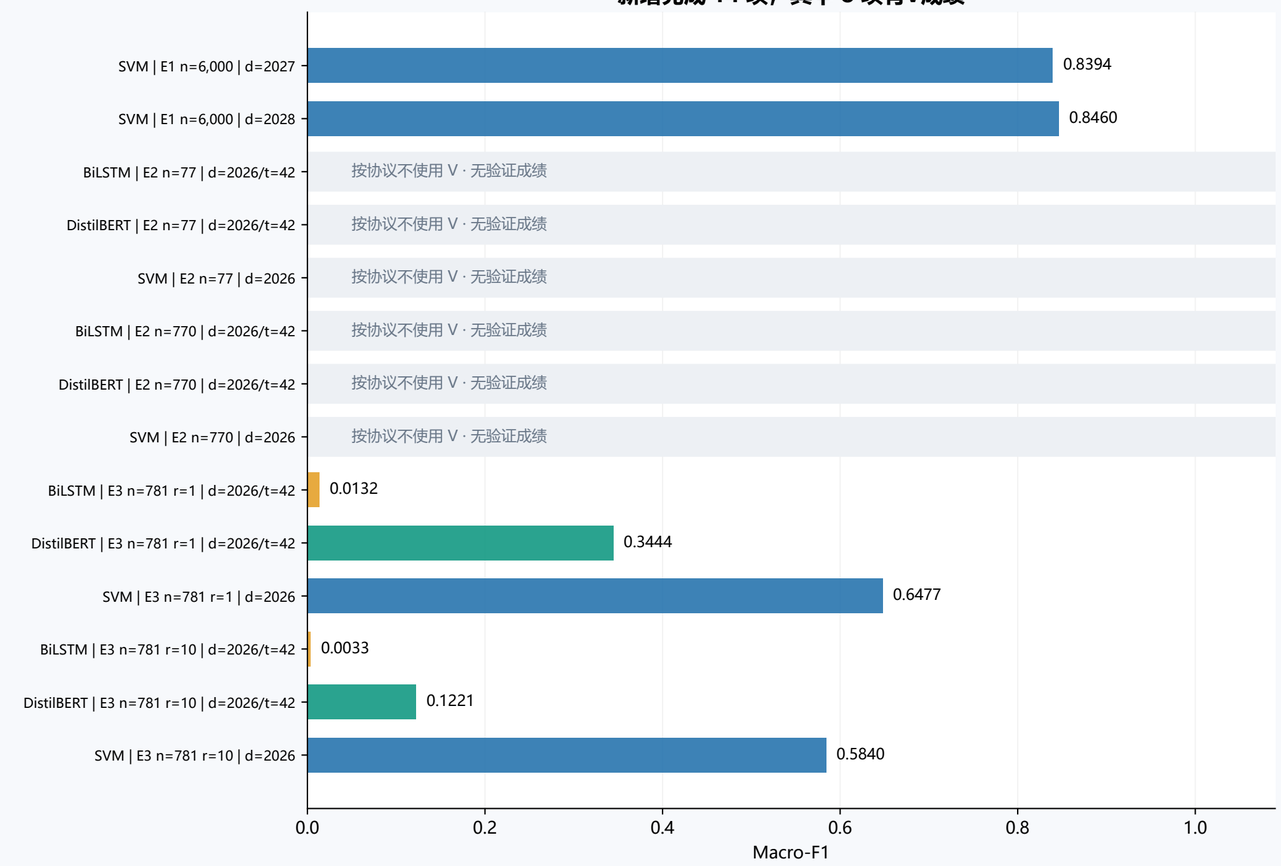
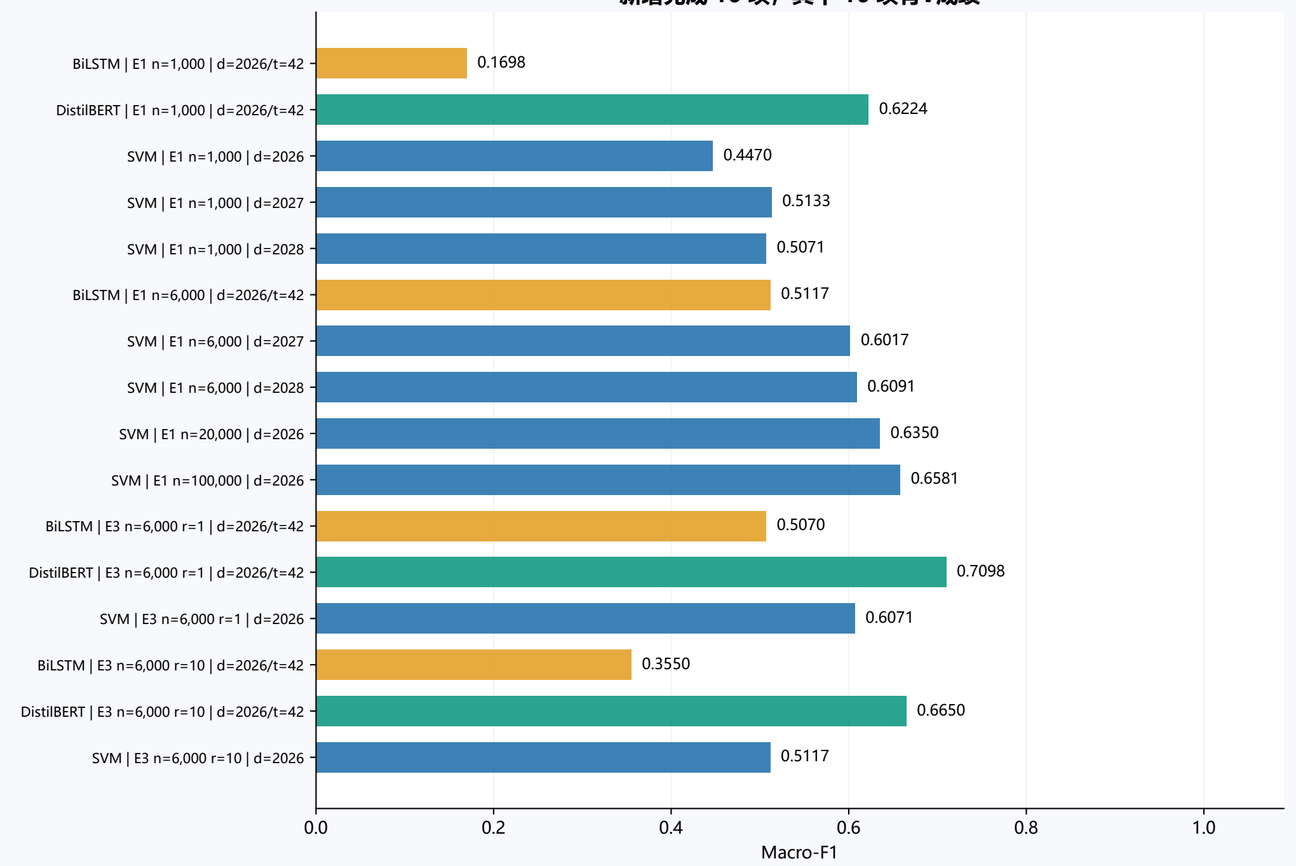
刚完成的全部 53 项新增训练：逐条结果

不同条件分行展示；d=数据种子，t=训练种子，r=请求类比例；灰行不代表0分







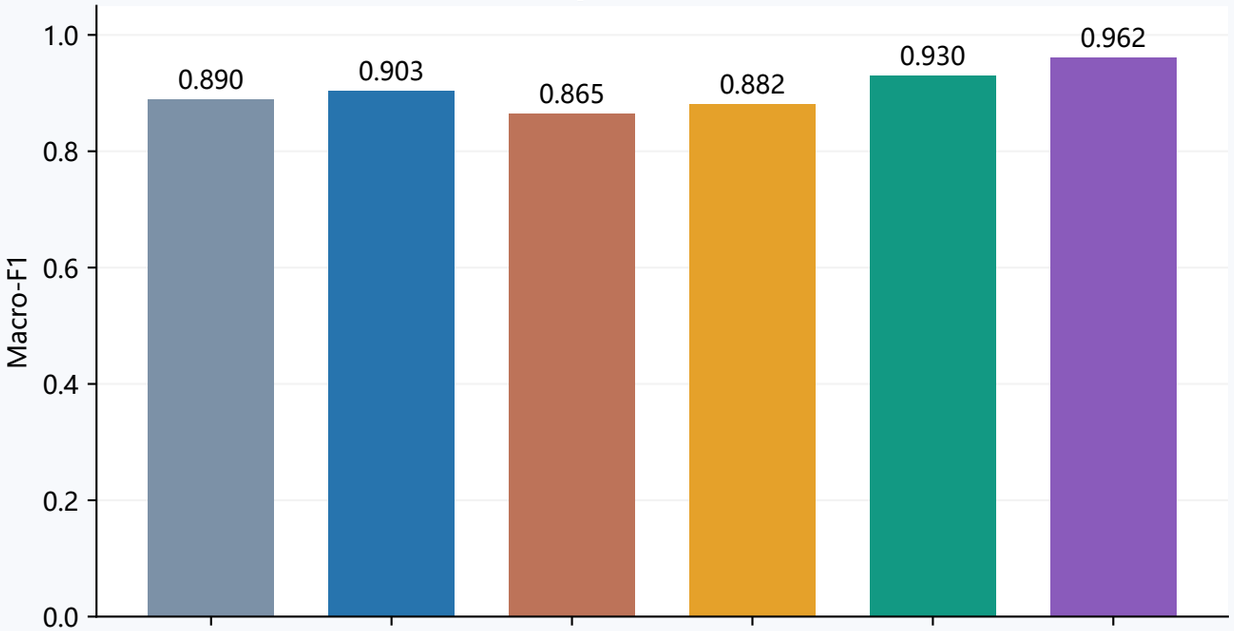


验证集 V 探索性结果；已用 V 选择检查点，不能作为独立正式测试集 Q 成绩。 快照：11月07日 22:23 SGT

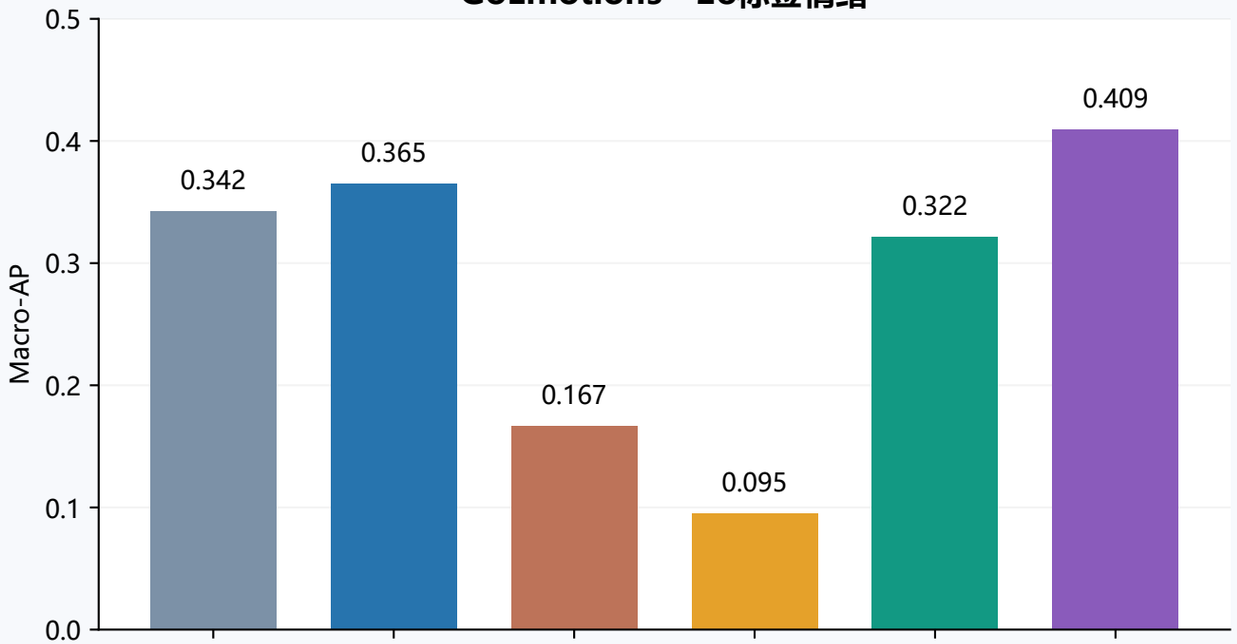
相同 6,000 条训练样本：全部六类模型

主数据种子2026；神经模型种子42；包含已有ModernBERT补充结果，不同任务指标分别展示

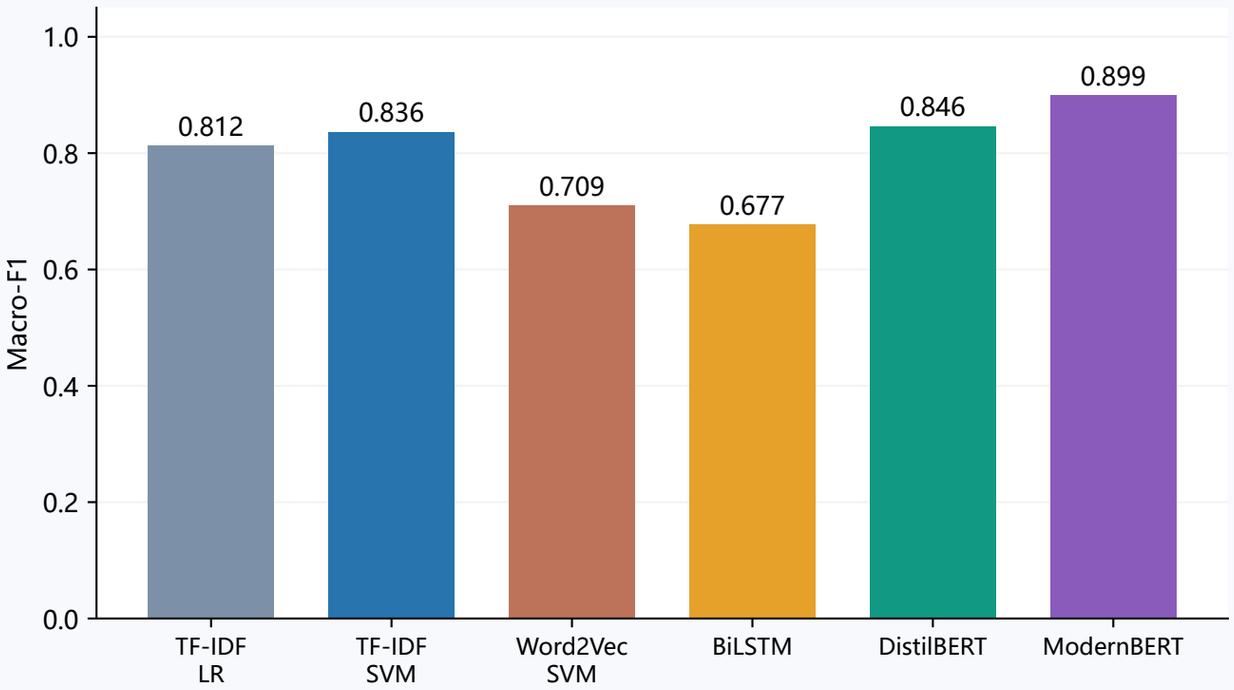
Yelp • 情感二分类



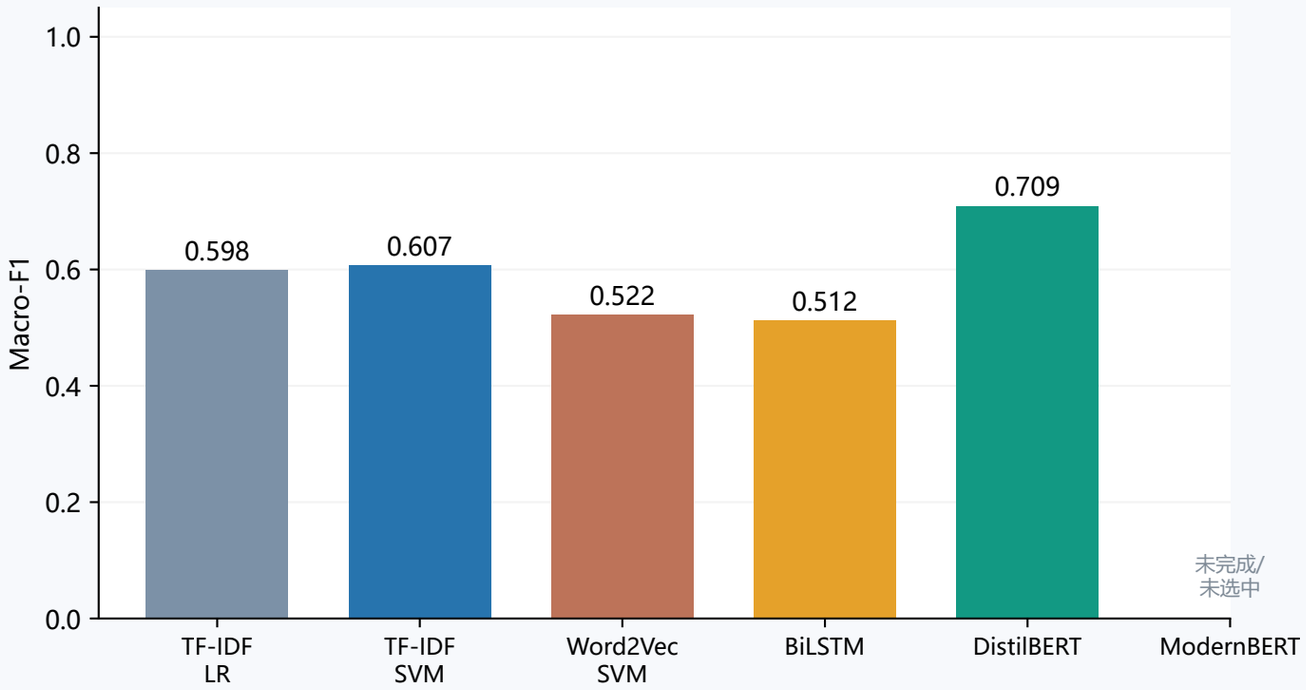
GoEmotions • 28标签情绪



BANKING77 • 77类意图



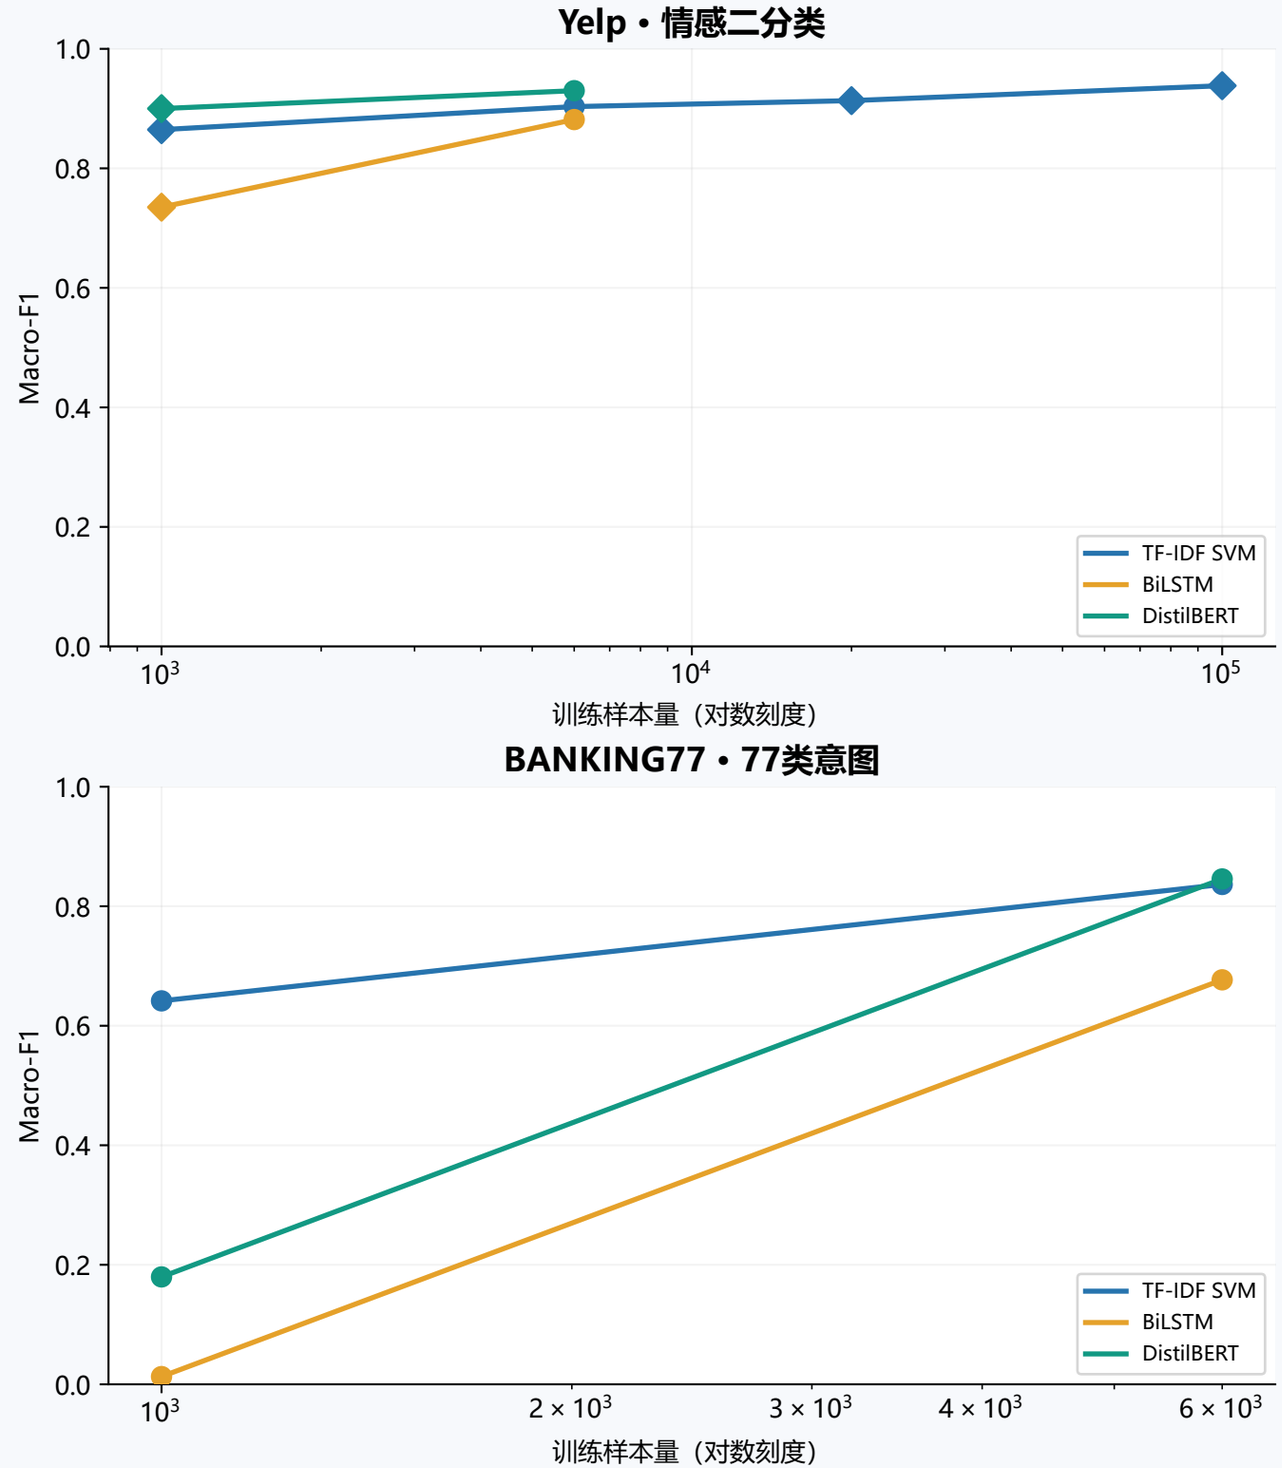
Yahoo • 10类主题

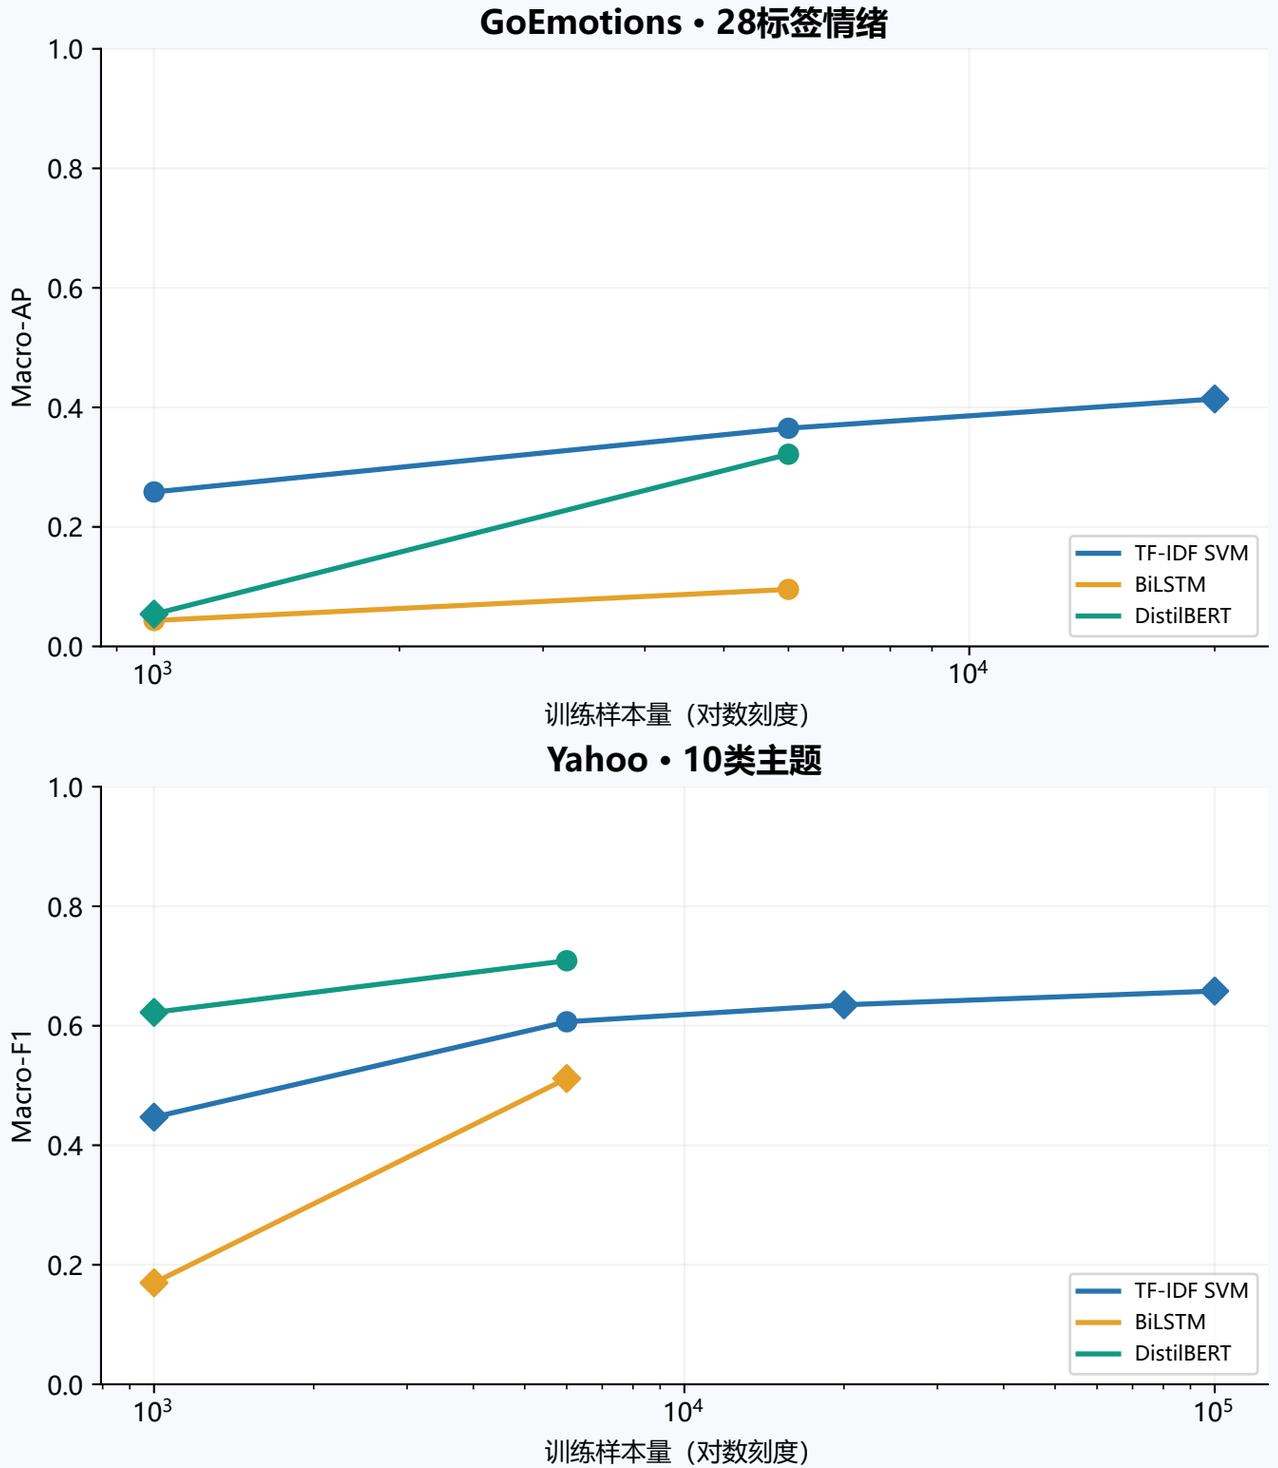


验证集 V 探索性结果；已用 V 选择检查点，不能作为独立正式测试集 Q 成绩。 快照：11月07日 22:23 SGT

样本量与验证表现

只连接实际完成点；主种子固定；◆ 新增训练，● 复用；缺失条件不插值

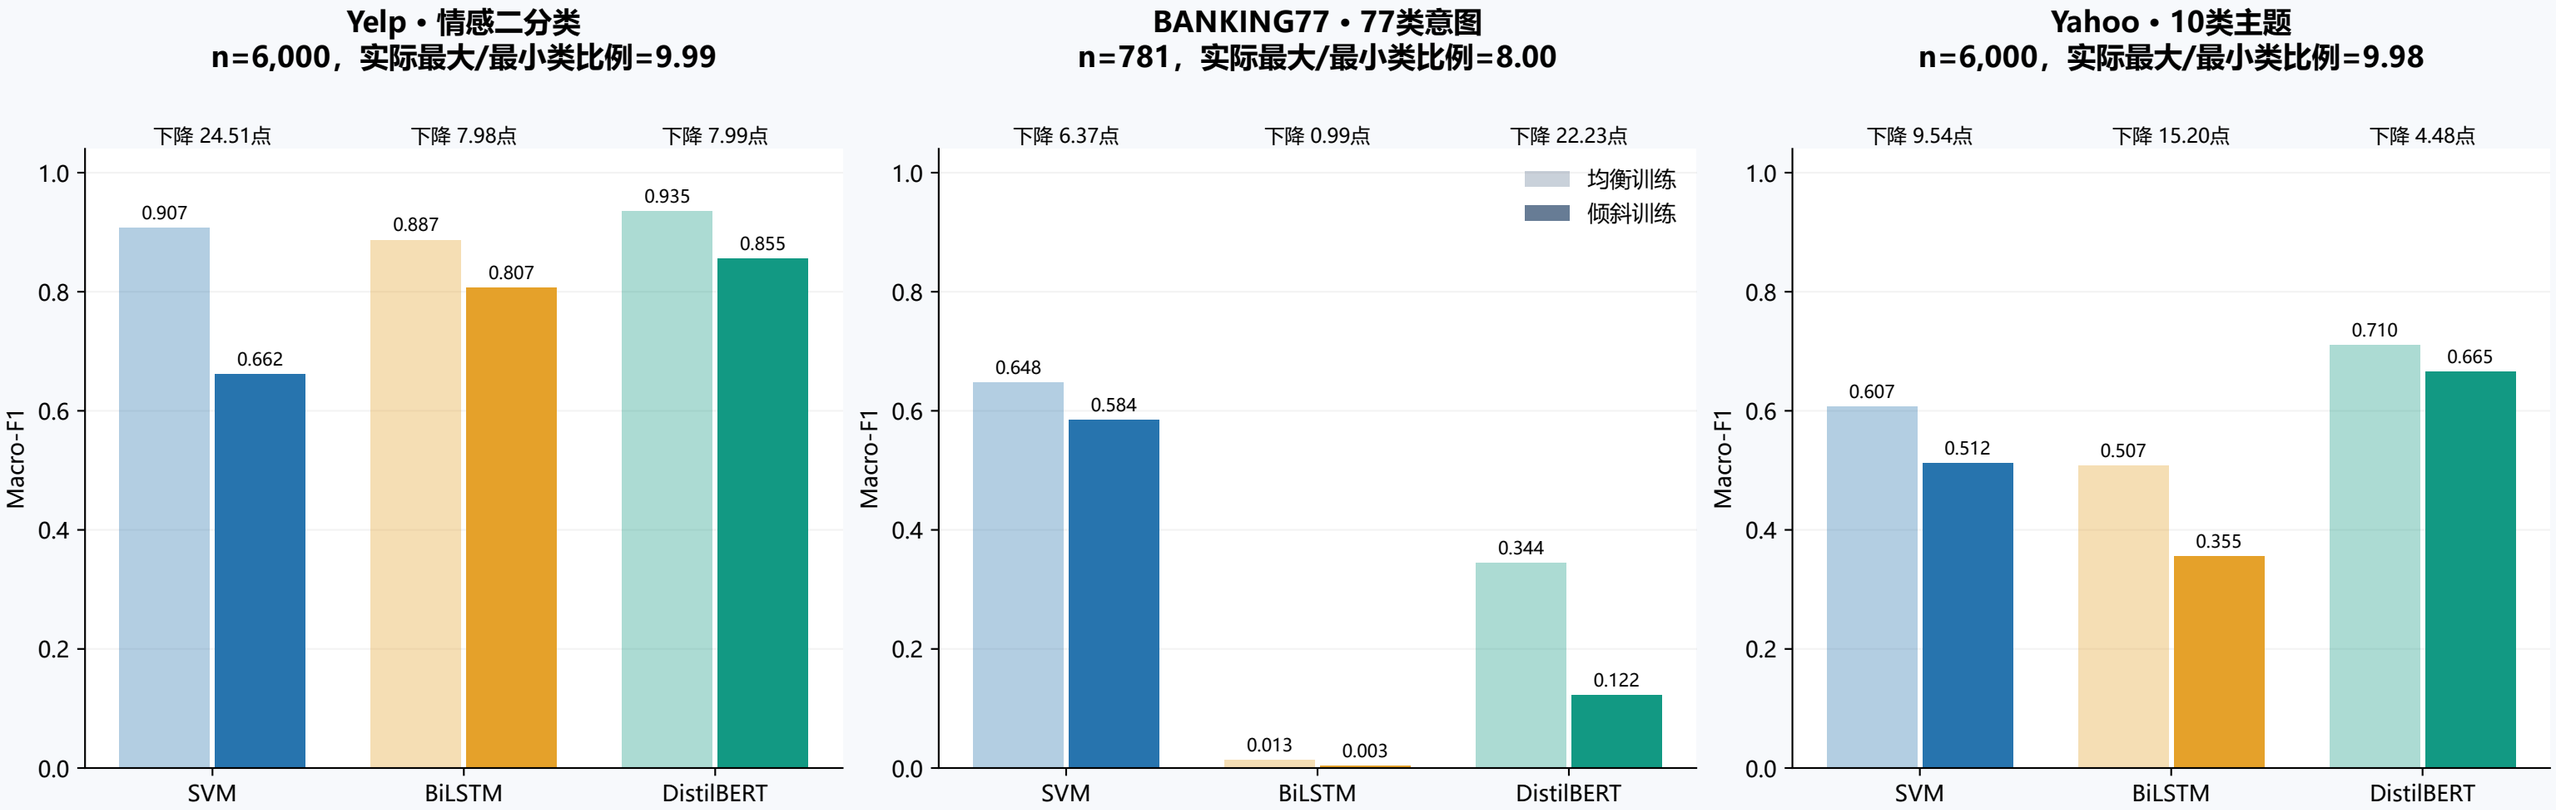




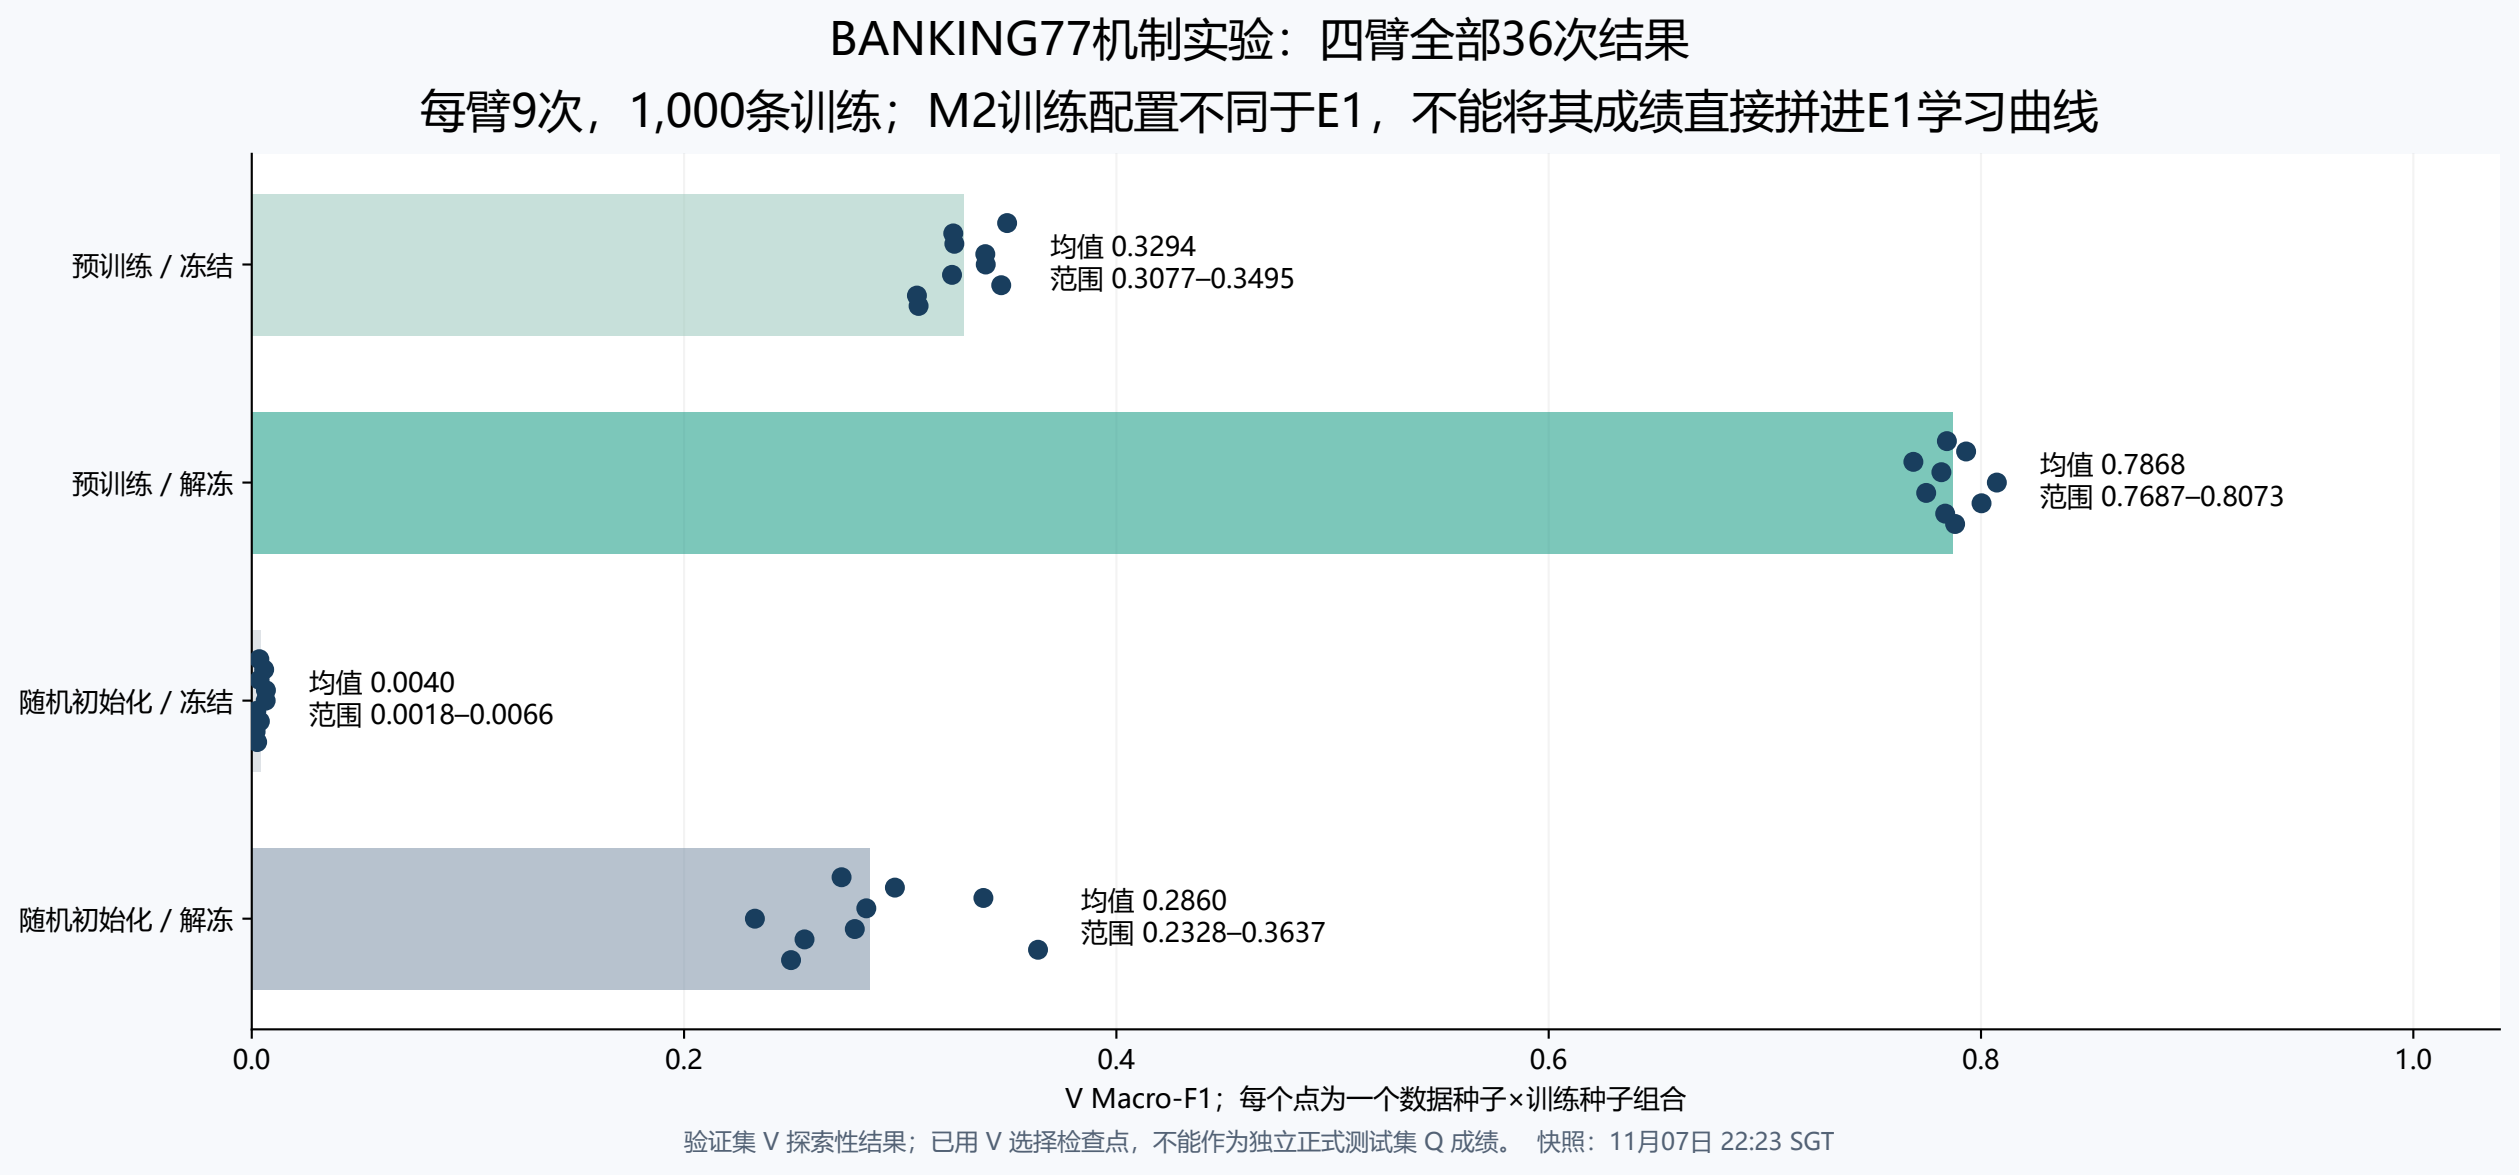
验证集 V 探索性结果；已用 V 选择检查点，不能作为独立正式测试集 Q 成绩。 快照：11月07日 22:23 SGT

训练分布倾斜后的变化：全部9组匹配对照

每个数据集内训练总量相同；样本组成也会变化；较小降幅不等于较高绝对性能

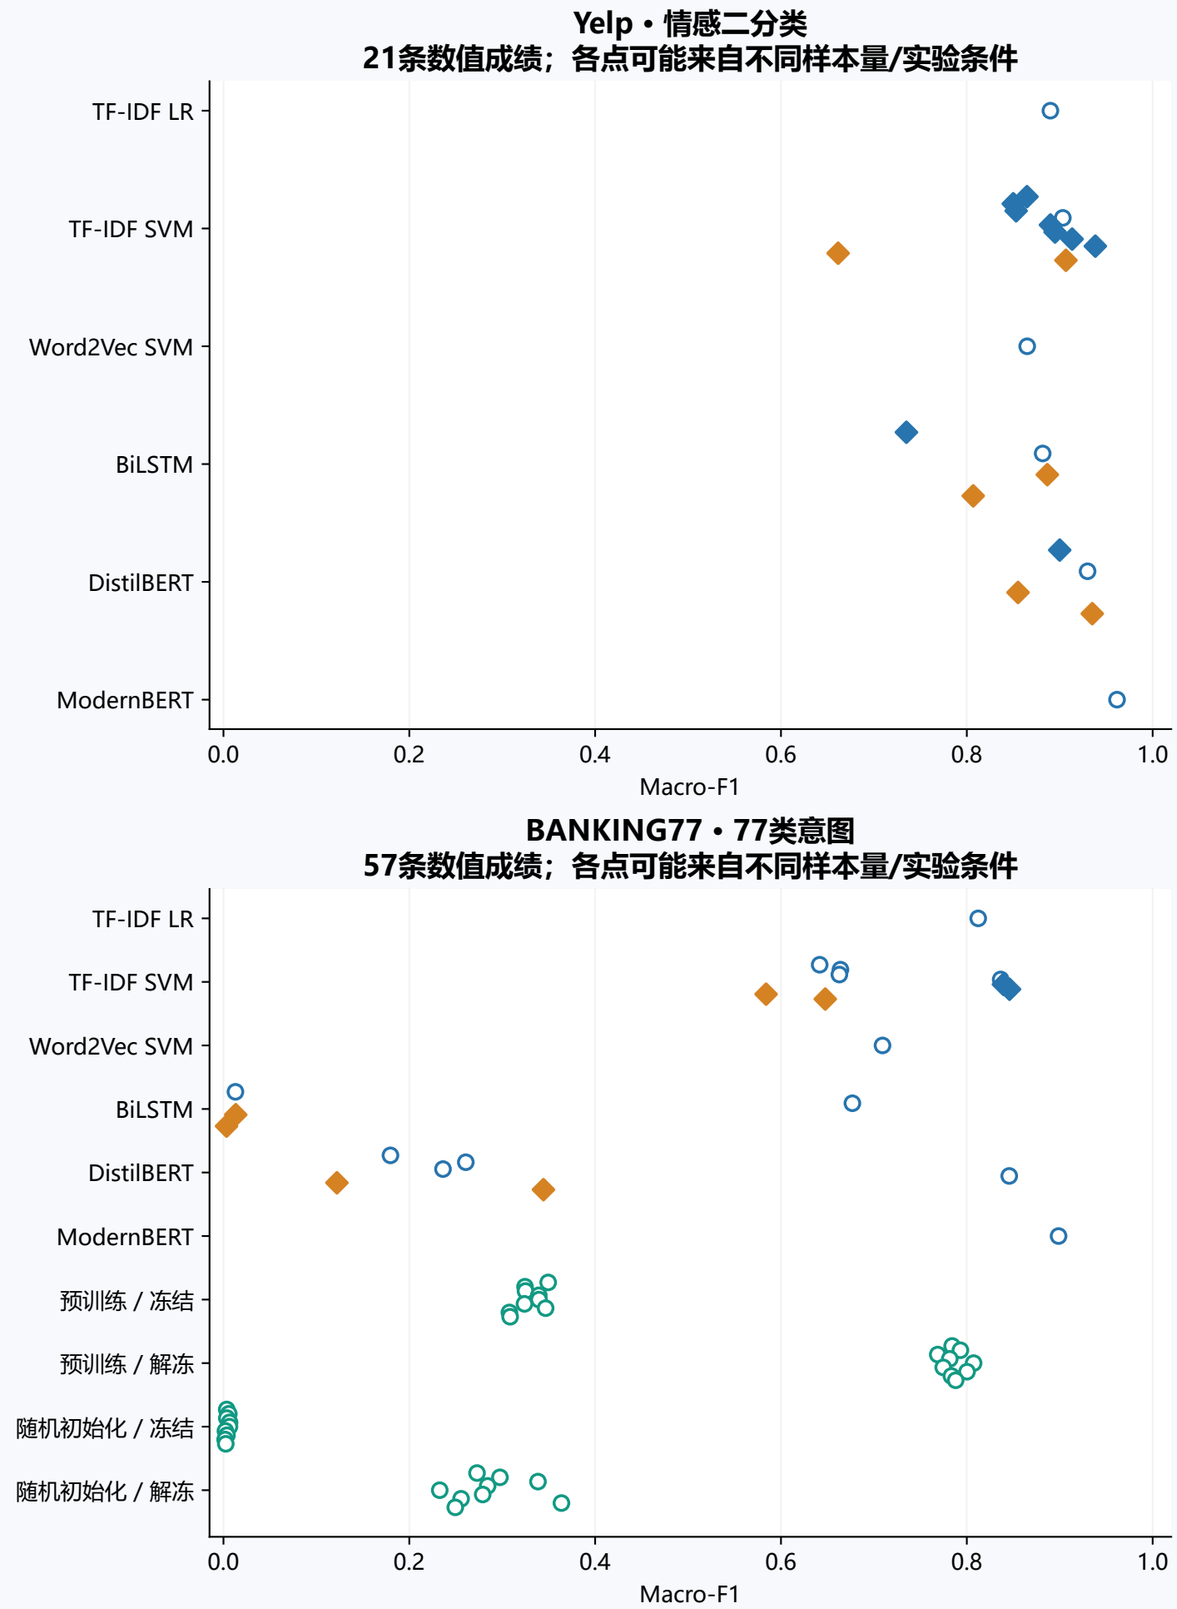


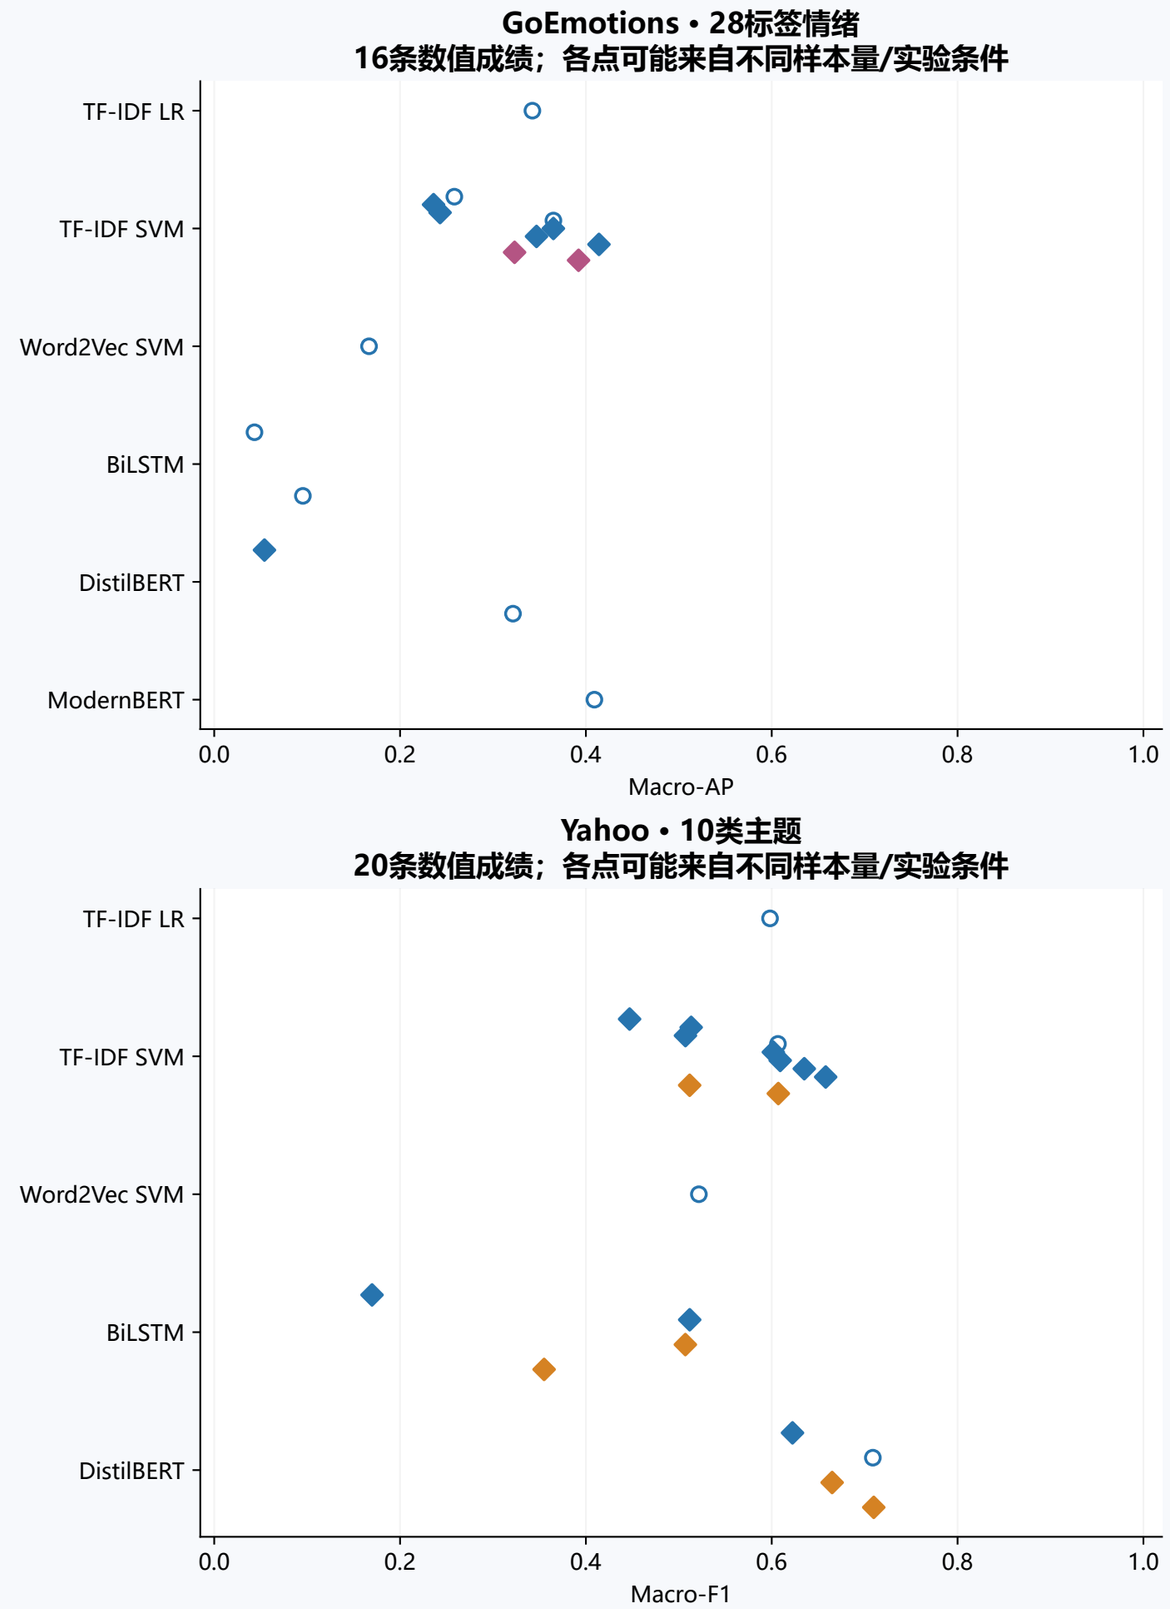
验证集 V 探索性结果；已用 V 选择检查点，不能作为独立正式测试集 Q 成绩。 快照：11月07日 22:23 SGT


BANKING77机制实验：四臂全部36次结果
每臂9次，1,000条训练；M2训练配置不同于E1，不能将其成绩直接拼进E1学习曲线
预训练 / 冻结
均值 0.3294
范围 0.3077–0.3495
预训练 / 解冻
均值 0.7868
范围 0.7687–0.8073
随机初始化 / 冻结
均值 0.0040
范围 0.0018–0.0066
随机初始化 / 解冻
均值 0.2860
范围 0.2328–0.3637
0.0
0.2
0.4
0.6
0.8
1.0
V Macro-F1；每个点为一个数据种子×训练种子组合
验证集 V 探索性结果；已用 V 选择检查点，不能作为独立正式测试集 Q 成绩。 快照：11月07日 22:23 SGT

全部可用验证成绩：114个点，一个不漏

颜色为实验条件；垂直错开仅为防重叠，不是误差条；不能跨条件将点云当作模型均值排名

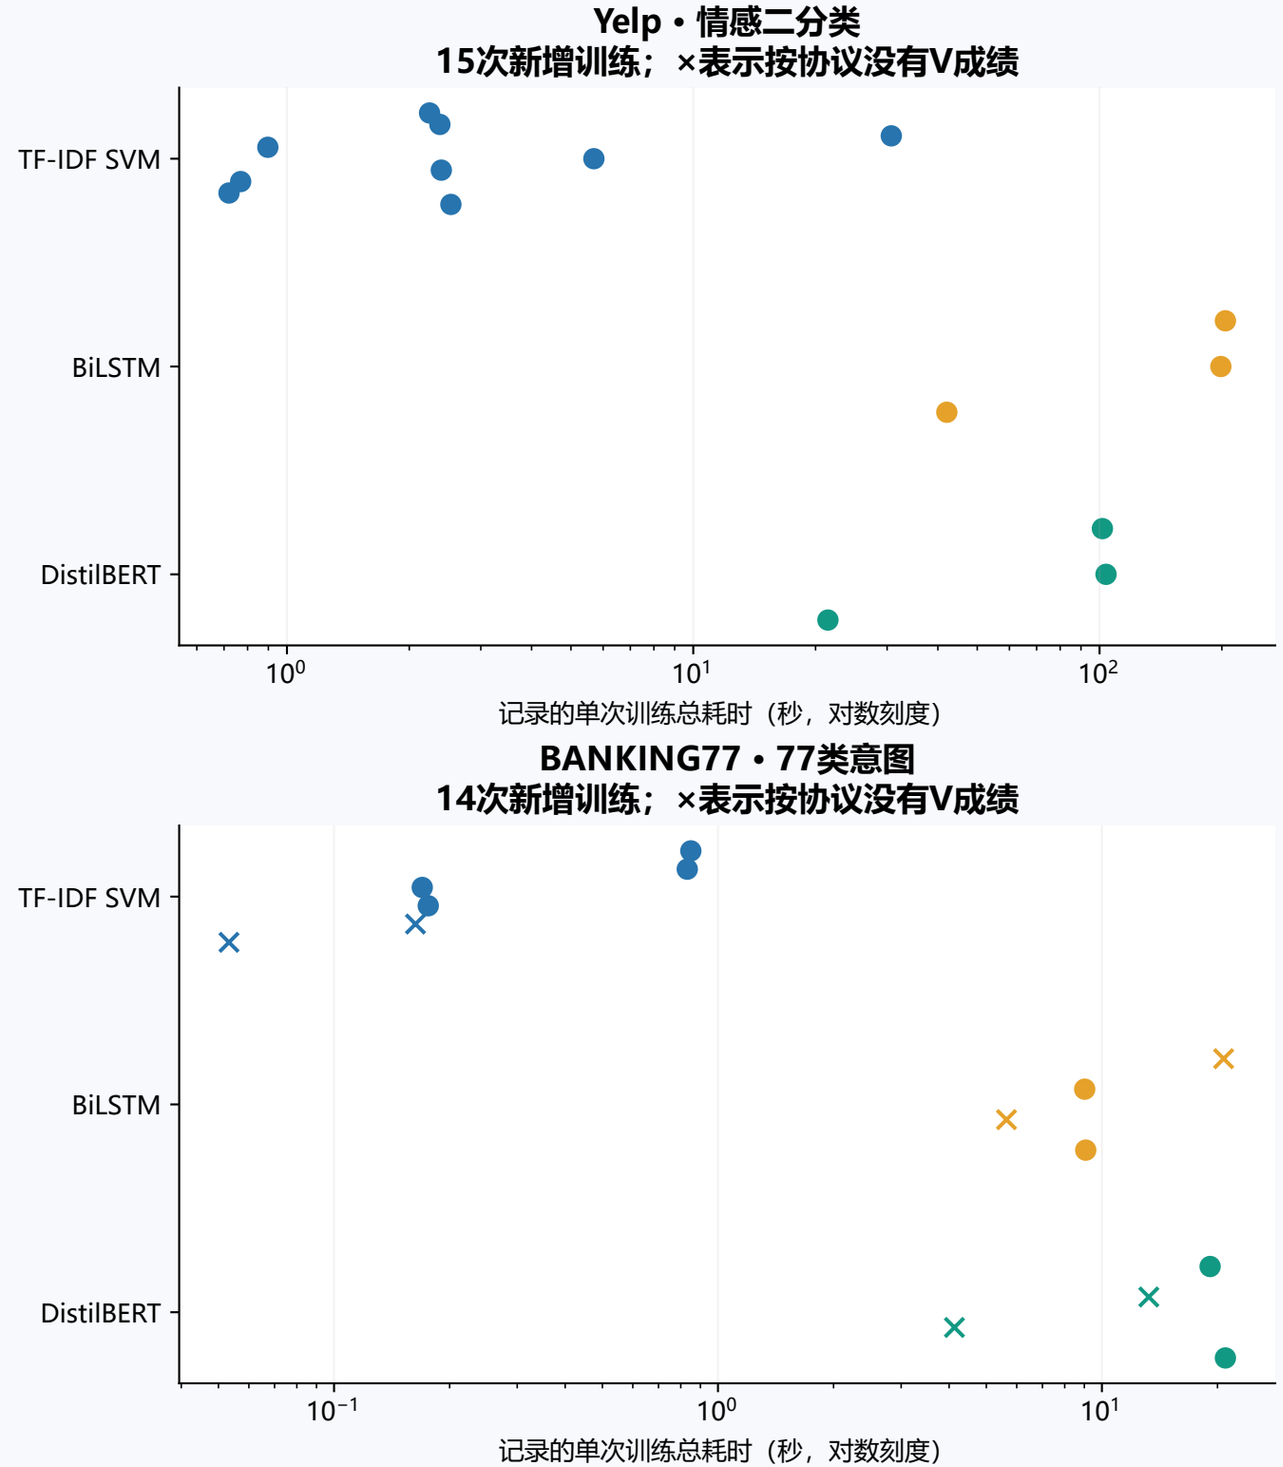


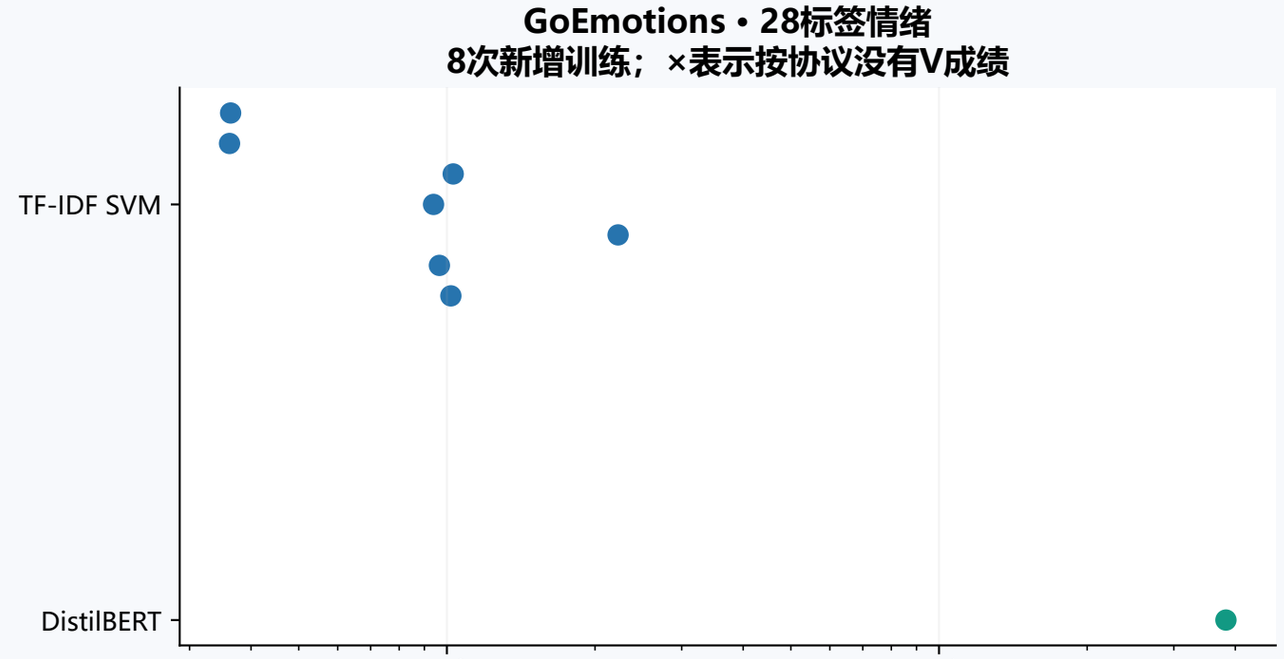


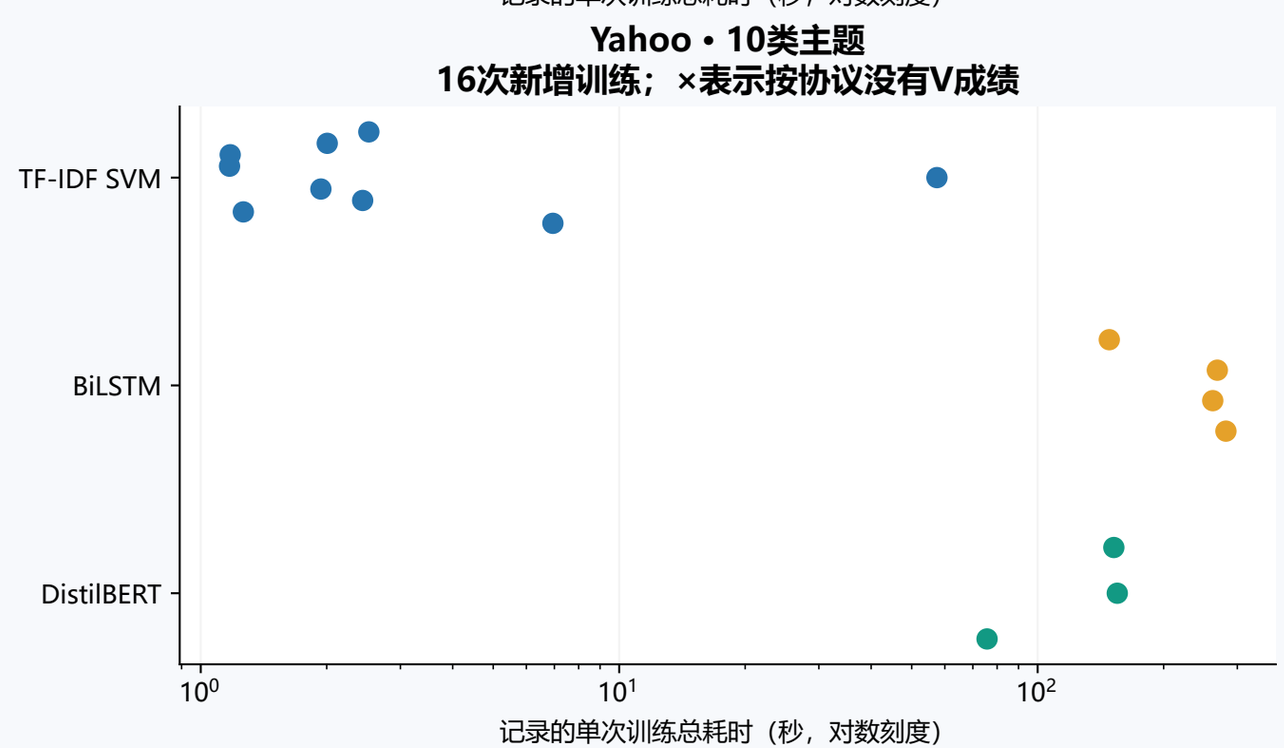
验证集 V 探索性结果；已用 V 选择检查点，不能作为独立正式测试集 Q 成绩。 快照：11月07日 22:23 SGT

刚完成的全部新增训练：记录耗时

各点的样本量、CPU/GPU和运行条件不相同；本图不能作为统一硬件上的速度排名



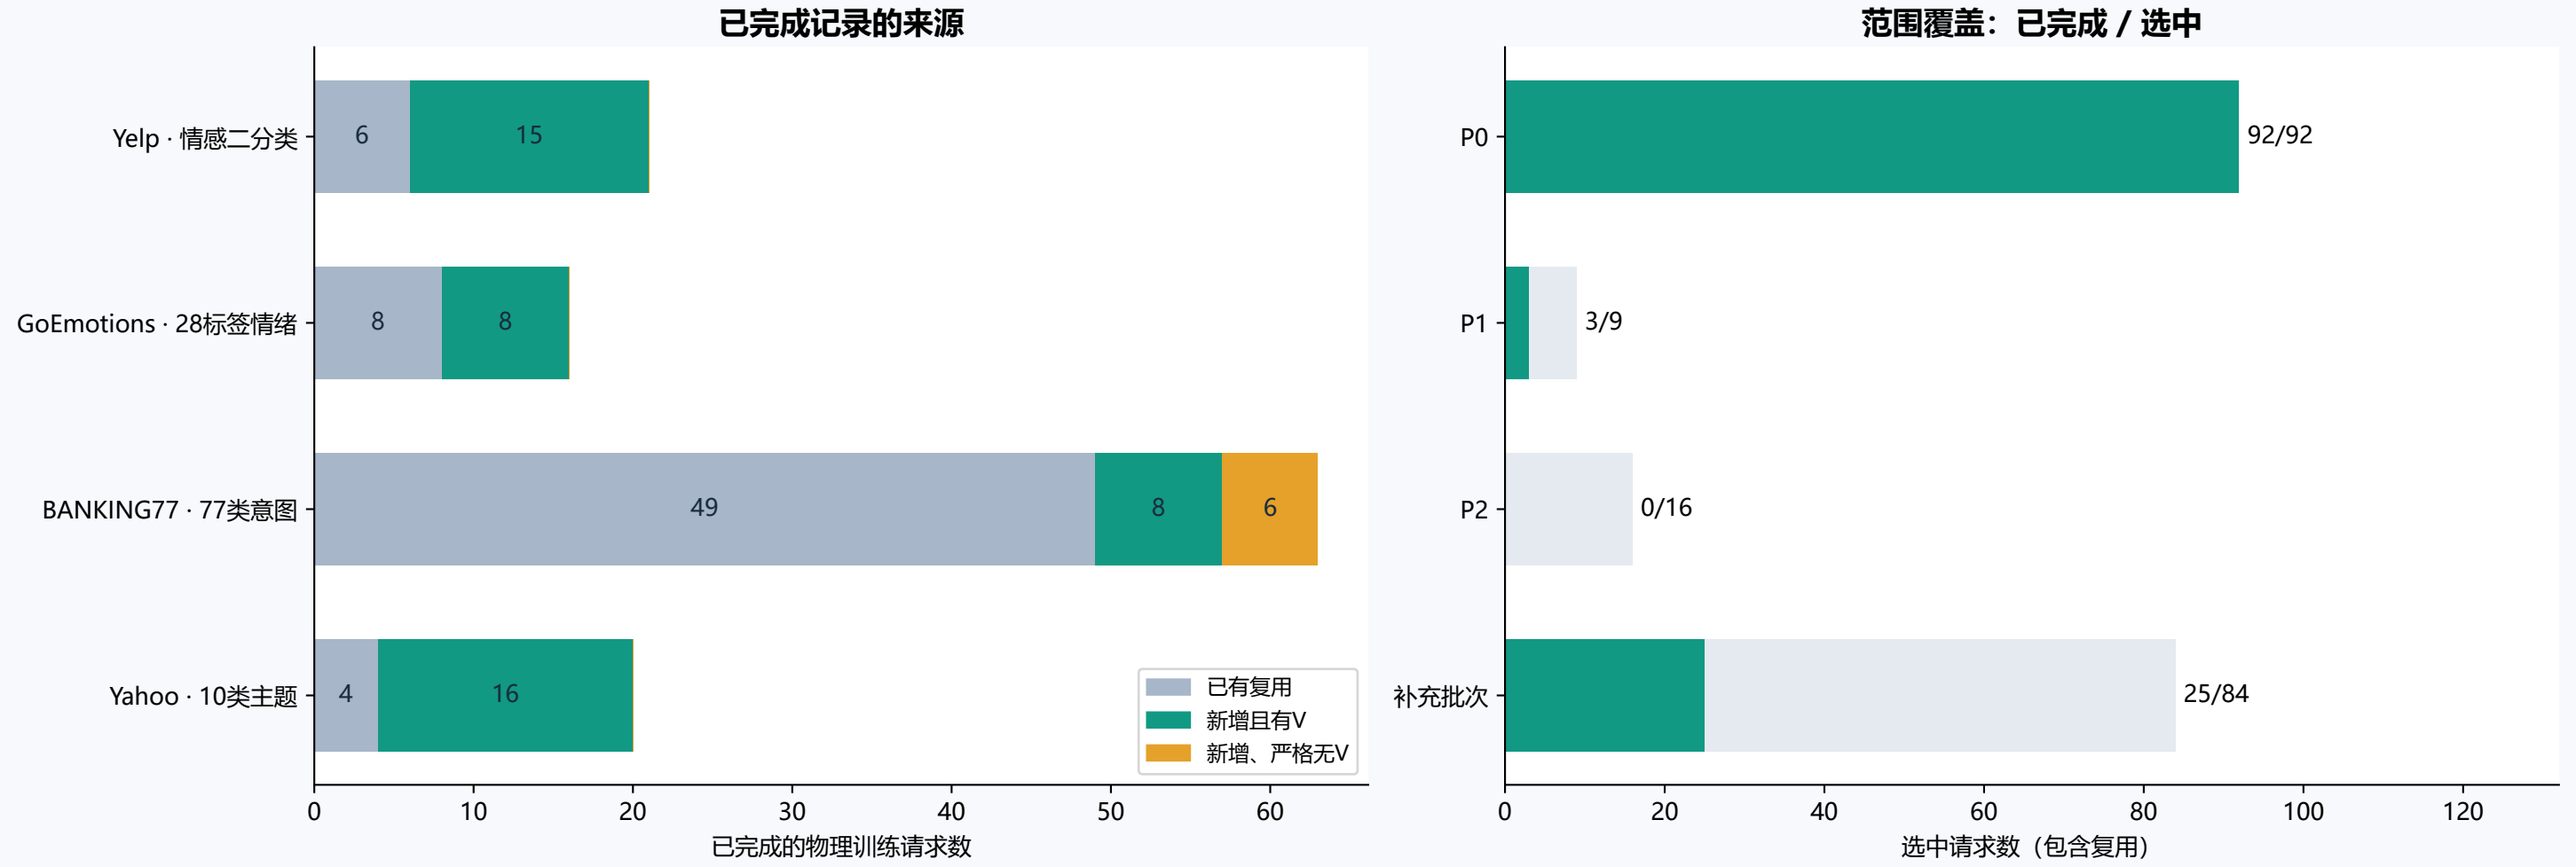




验证集 V 探索性结果；已用 V 选择检查点，不能作为独立正式测试集 Q 成绩。 快照：11月07日 22:23 SGT

数据完整性：选中201项，已完成120项，待完成81项

可画验证成绩 114项；按协议无V 6项；正式Q未运行



验证集 V 探索性结果；已用 V 选择检查点，不能作为独立正式测试集 Q 成绩。 快照：11月07日 22:23 SGT