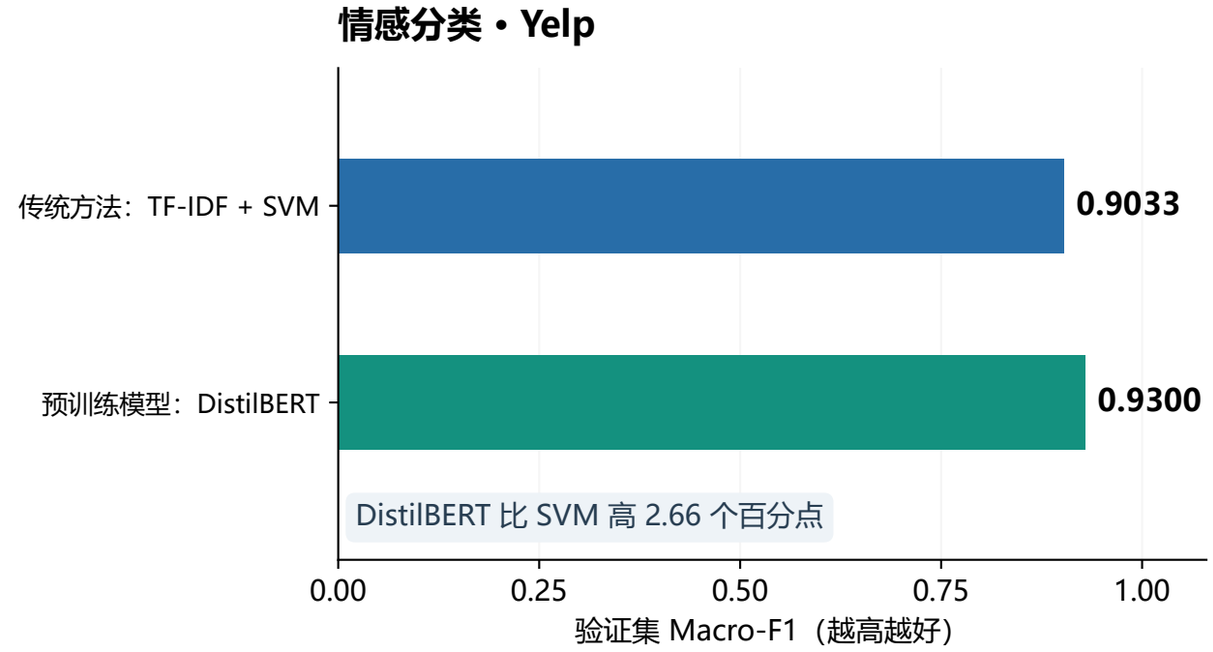
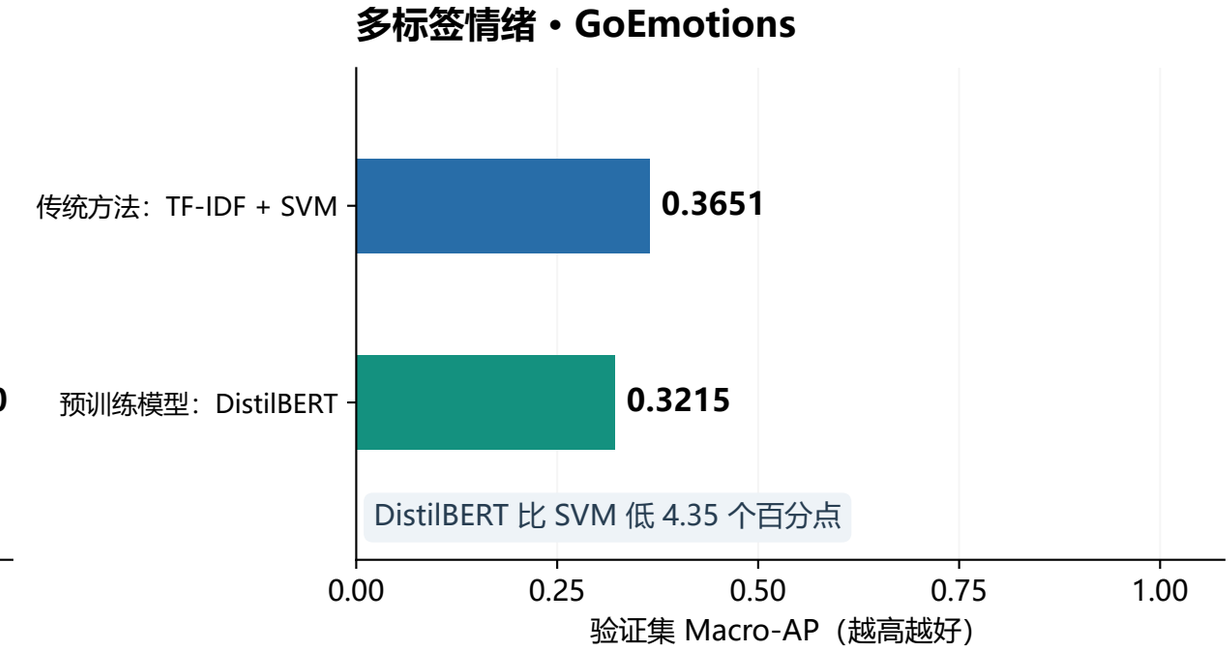
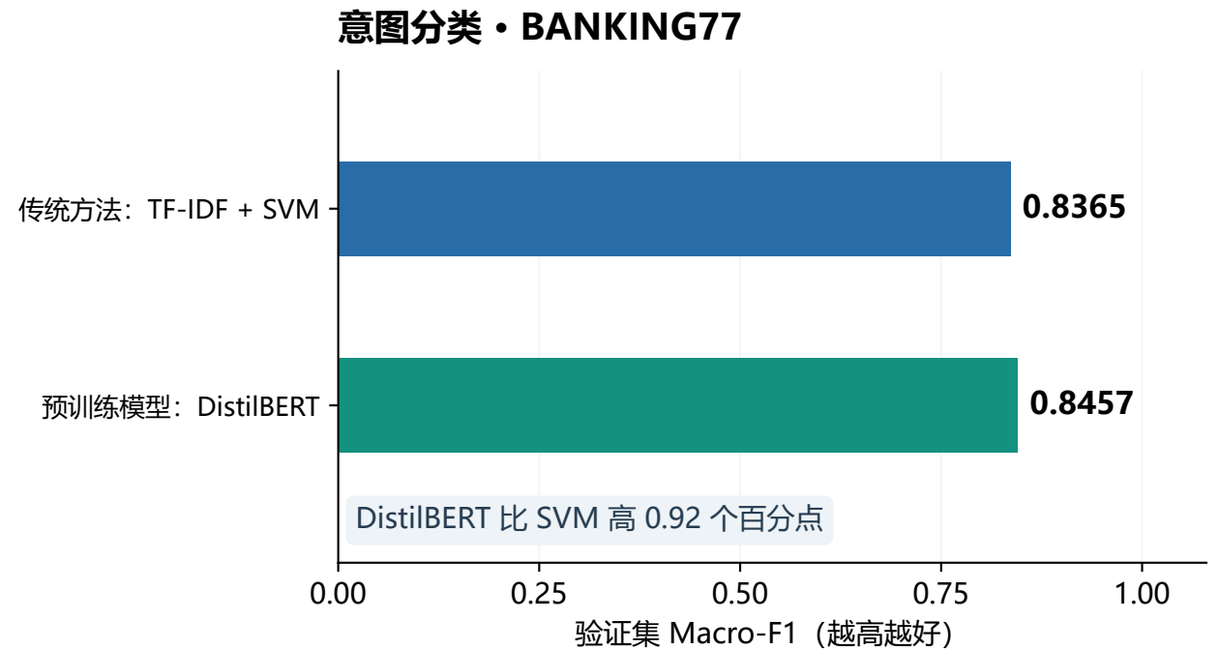
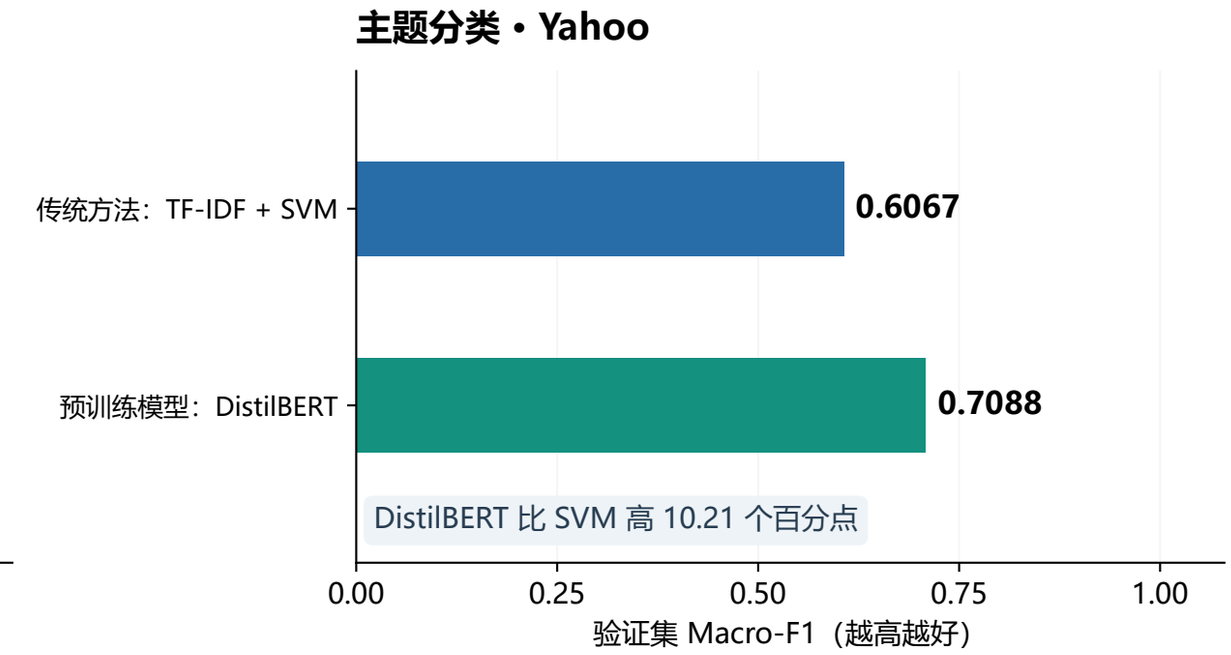
① 同样的训练数据，传统 SVM 和 DistilBERT 差多少?

固定：每个任务内，同样6,000条训练文本、同一个验证集。只改变模型。







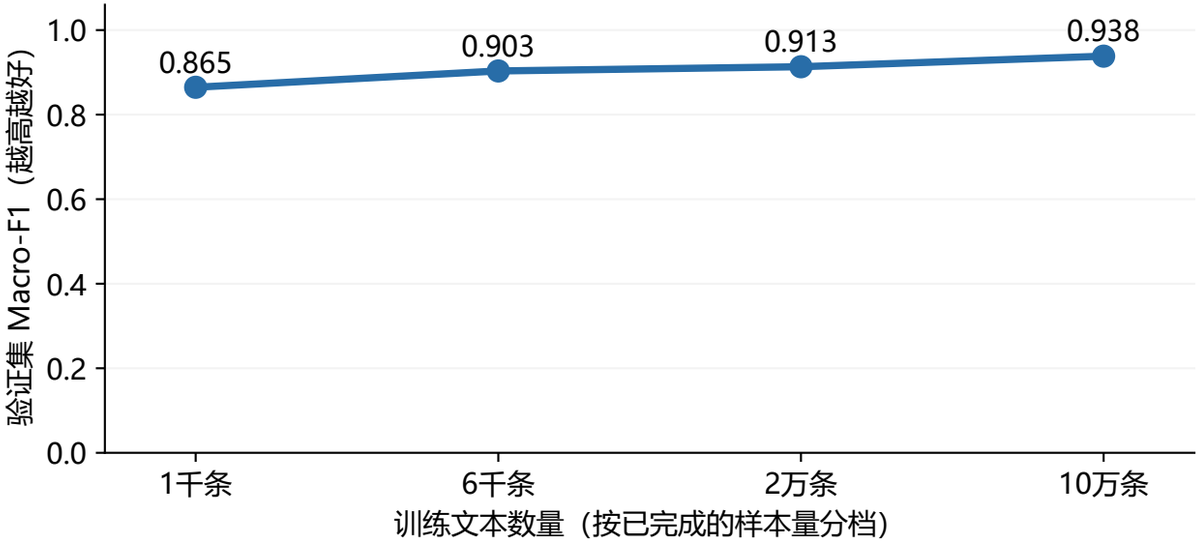


所有分数来自验证集，已用于选检查点；并非独立测试成绩。主图为固定种子的单次结果。

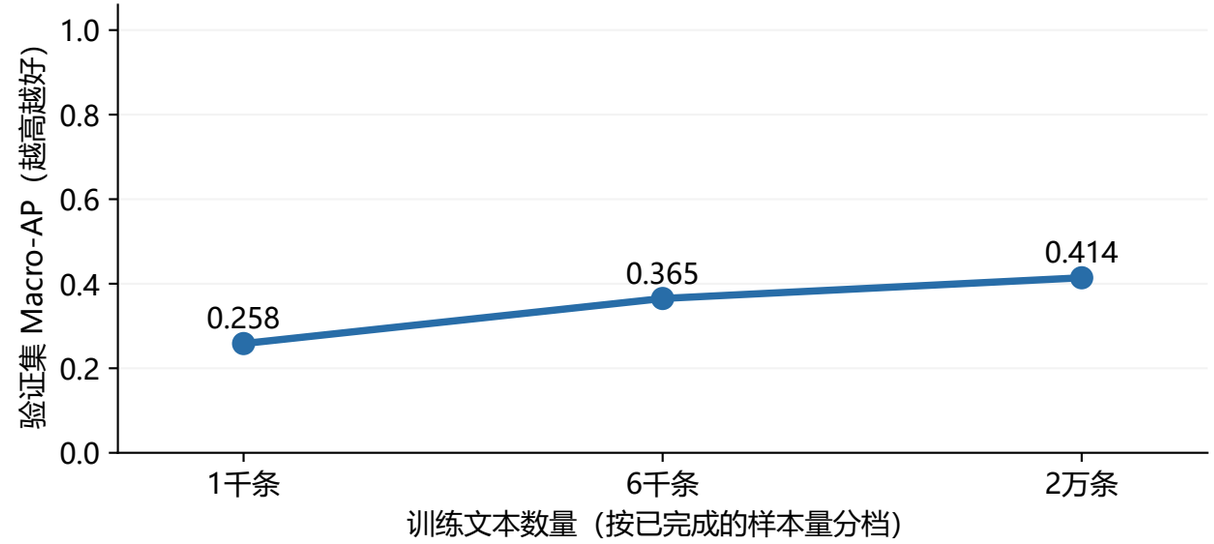
② 如果一直用传统 SVM，增加训练文本有帮助吗？

固定：模型都是 TF-IDF + SVM，同一任务使用同一个验证集。只改变训练样本量。

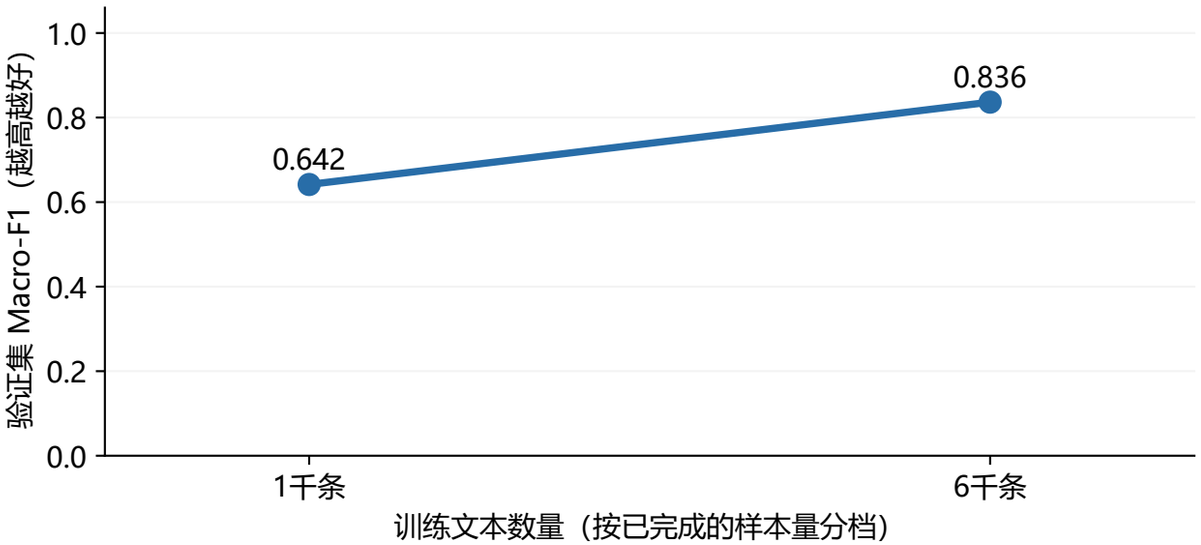
情感分类 • Yelp
最少到最多样本：增加 7.36 个百分点



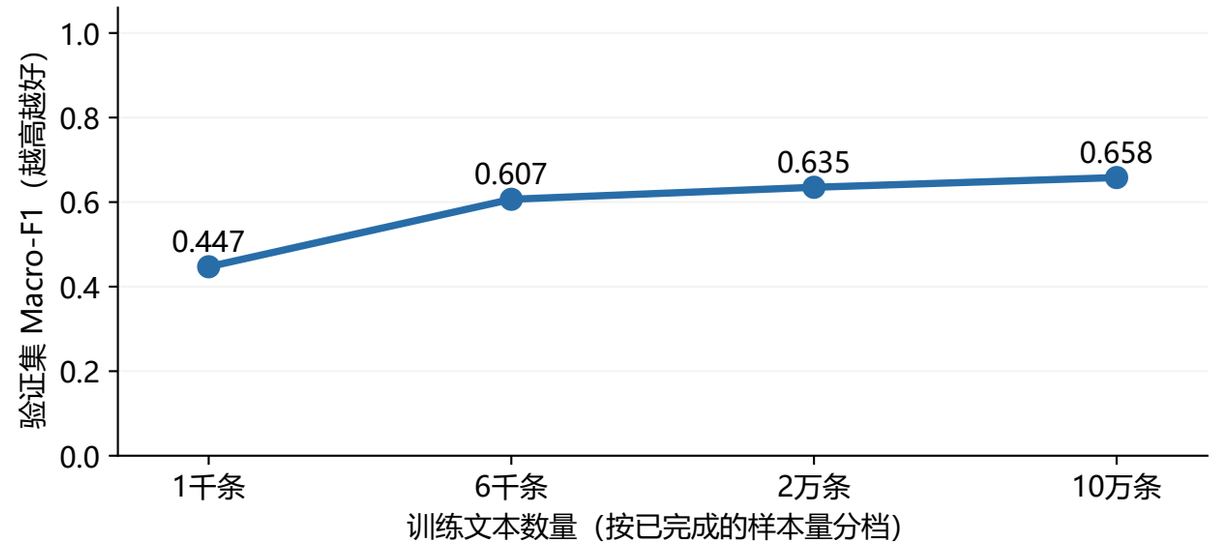
多标签情绪 • GoEmotions
最少到最多样本：增加 15.57 个百分点



意图分类 • BANKING77
最少到最多样本：增加 19.48 个百分点



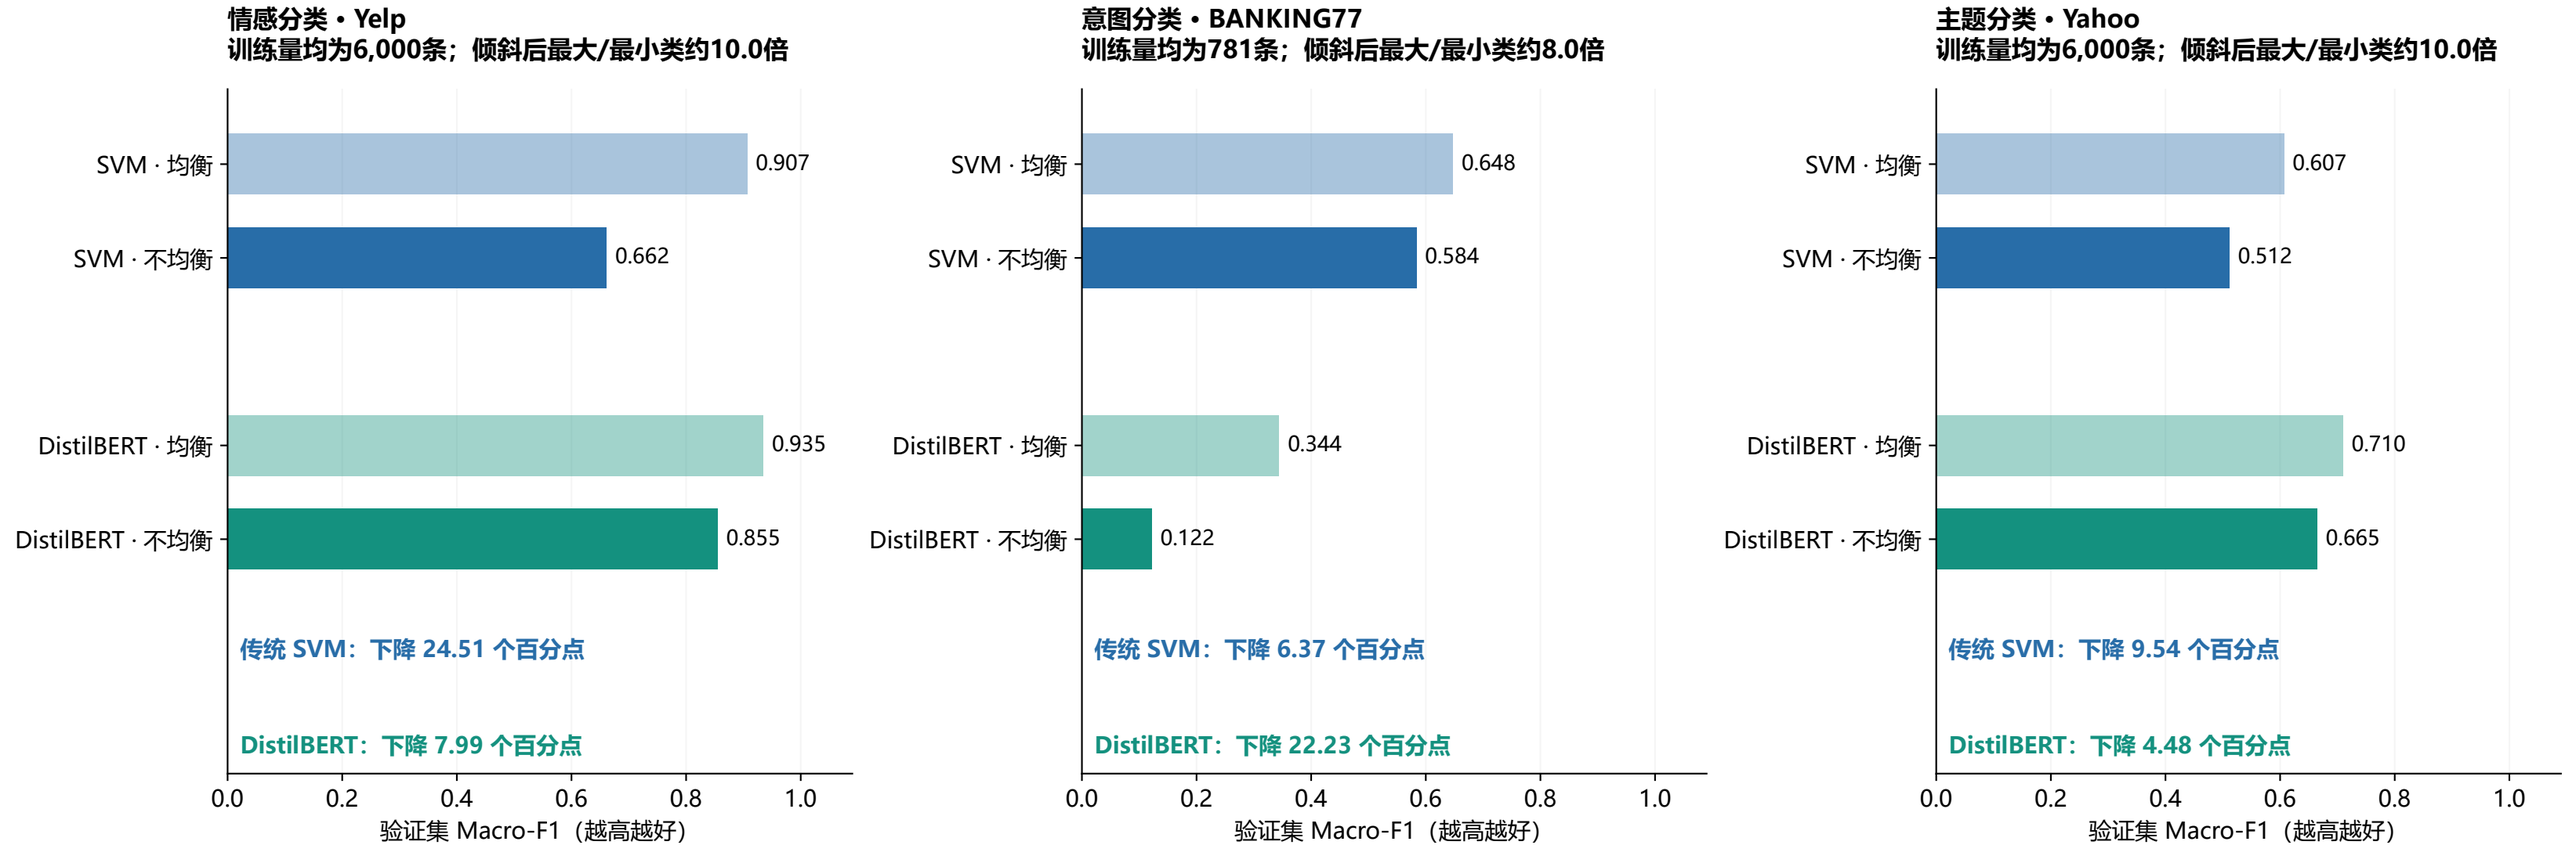
主题分类 • Yahoo
最少到最多样本：增加 21.10 个百分点



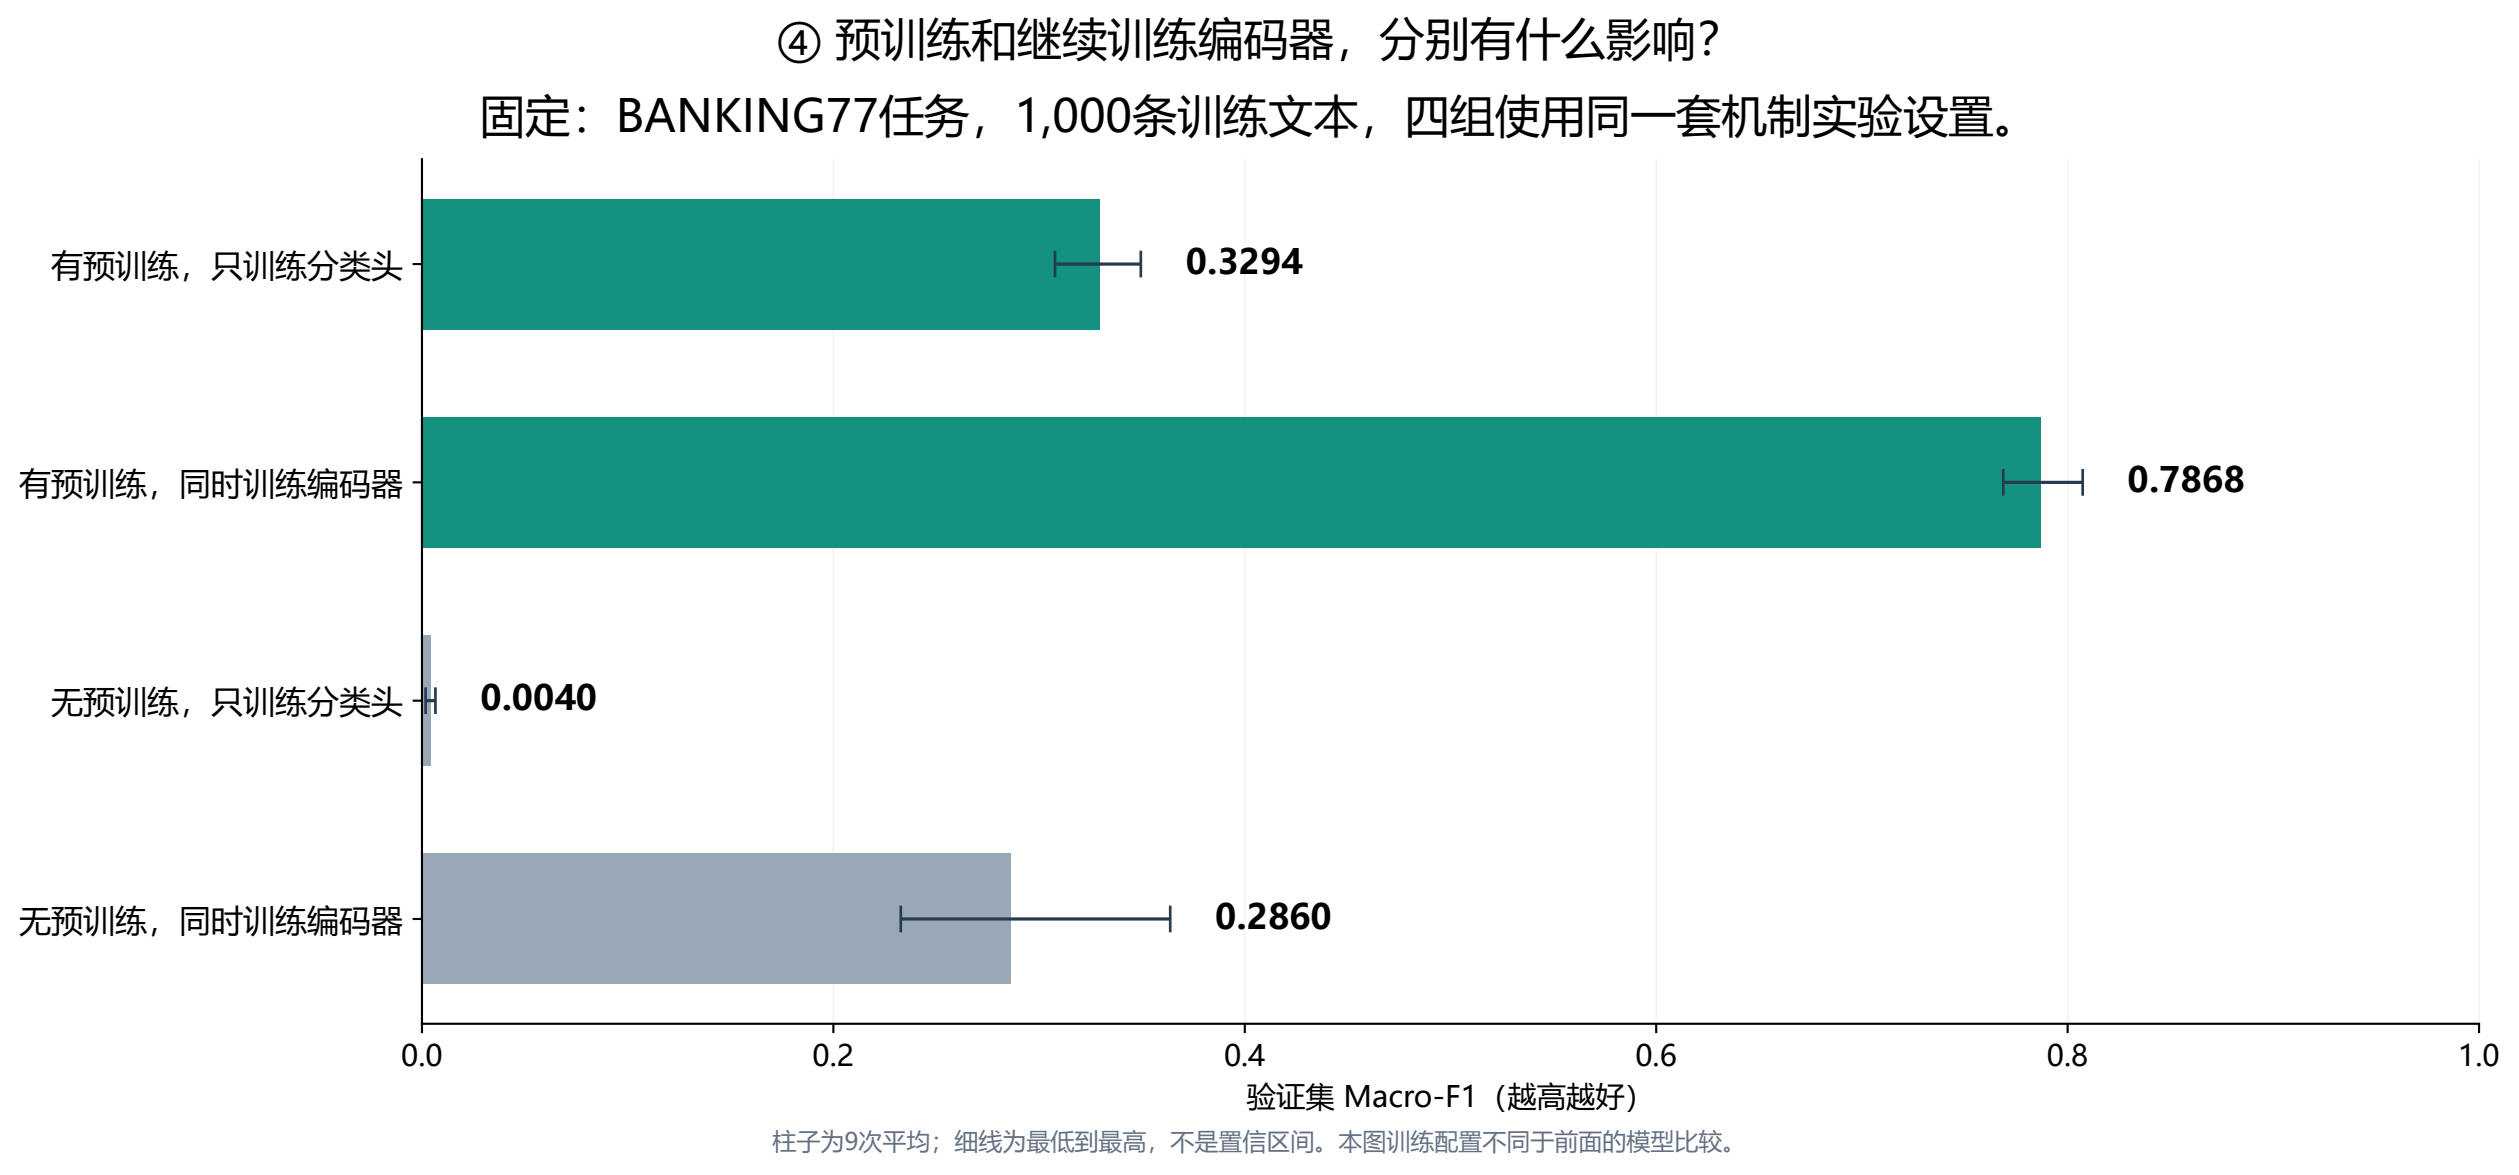
所有分数来自验证集，已用于选检查点；并非独立测试成绩。主图为固定种子的单次结果。

③ 训练数据变得不平衡，两个模型各下降多少?

固定：每个任务内训练总量不变，验证集不变。比较“均衡训练”和“不均衡训练”。



本图为验证集结果；样本组成也随抽样改变，不能视作已隔离所有因素的因果效应。


④ 预训练和继续训练编码器，分别有什么影响？
固定：BANKING77任务，1,000条训练文本，四组使用同一套机制实验设置。
有预训练，只训练分类头
0.3294
有预训练，同时训练编码器
0.7868
无预训练，只训练分类头
0.0040
无预训练，同时训练编码器
0.2860
0.0
0.2
0.4
0.6
0.8
1.0
验证集 Macro-F1（越高越好）
柱子为9次平均；细线为最低到最高，不是置信区间。本图训练配置不同于前面的模型比较。