文本分类模型在不同数据条件下的能力边界与失败机制

承接交接前常规分类、MultiNLI与AG News长尾比较：从条件性优势的发现，推进到规模、优化与机制解释。

主问题一 · 能力边界：什么数据条件下，模型占优、退化或持续出错?

主问题二 · 失败机制：优化、表征、标注支持与词汇依赖如何影响失败?

统一起点：在同一数据条件内，比较 TF-IDF + SVM、BiLSTM、DistilBERT；再观察数据量、类别分布与输入表达改变后的表现。

以下五条是并列的研究分支；每一行从左向右阅读。

	① 从比较中发现的现象	② 由现象追问的子问题	③ 对应的实验与证据	④ 目前得到的解释
数据规模	从1k增至6k后， 部分错误得到纠正， 也存在持续错误与新增错误。	哪些错误可以靠加数据缓解? 哪些错误需要进一步解释?	E1 规模对照 + S2 错误轨迹 四任务、三模型、24个模型的D预测 形成12组同样本1k→6k轨迹。	数据规模效应具有选择性：加数据能纠错， 也可能引入新错。持续错误已定位； 具体语义失败模式仍待系统归纳。 D轨迹已完成 · 语义归因待补
优化配方	早期一些条件下， SVM分数超过神经模型； 延长训练后部分排序改变。	是模型能力差异，还是 训练预算、学习率和调度 影响了比较结果?	S1 学习率×预算 + 新配方网格 动态早停、最优配方3个种子 18个最终/参考模型完成独立Q测试。	优化配方能改变部分早期排序。两已测条件 Q均为 DistilBERT > SVM > BiLSTM。 Bank F1：0.816 / 0.658 / 0.510；Go AP：0.398 / 0.336 / 0.201。 S1与新配方均已有Q结果
预训练表征	预训练模型与从头训练模型 在低数据条件下， 表现存在明显差距。	优势来自预训练表征， 还是来自编码器在 下游任务中的适配?	M2 同架构、同分类头初始化 预训练/随机初始化 × 冻结/解冻 BANKING77 1k四臂重复对照。	本配方下，初始化与编码器适配都影响结果； 预训练 + 解冻表现最好。 这为低数据表现差异提供局部表征解释。 V上的受控证据 · 未做此分支Q
长尾与支持	类别分布倾斜后， 不同模型的退化幅度不同， 这种相对优势还随任务改变。	尾类失败是因为独立标注少， 还是因为训练中 尾类的贡献较小?	E3 长尾对照 + S3 固定表示干预 标注支持完整/删减 × 贡献均匀/偏斜 两种固定表示，共8格。	固定TF-IDF+SVM、贡献均匀时，删减尾类标注 使Q Macro-F1从0.654降至0.453； 尾类召回65.6%→10.4%，本组均匀贡献不能替代标注支持。 S3独立Q已完成8格
词汇变化	原文分类表现较好， 仍可能因词汇表达变化 而发生预测翻转。	模型是否依赖表层线索? 线索词替换是否比普通 词汇替换更容易造成失败?	S4 / M1 匹配词汇干预 37对Gemini审核样本；两个固定模型 原文 / 线索词替换 / 控制词替换。	这组样本中，DistilBERT对线索替换更稳定。 相对控制替换，准确率降幅： SVM 24.3个百分点，DistilBERT 8.1个百分点。 AI审核样本上的配对干预证据

证据口径：V = 验证集；D = 探索样本；Q = 正式测试集。Q中的神经模型分数为3个种子均值，SVM为确定性单次结果。

这些分支共同回答“优势何时改变、失败与哪些因素有关”；各分支结论限于已测任务、数据条件和配方，不能跨任务拼成统一因果解释。