研究接续：从交接前的比较，走向当前的机制解释

同一主线逐步深入：先发现模型表现具有条件性，再检验规模、优化、表征和监督信息的作用。

	交接前已经得到的发现	由此继续追问	当前实验怎样推进
性能与成本	四套常规任务：LR与DistilBERT 在IMDb/Yelp差距不足1点， RT/AG News差距更大；传统推理更快。	优势为什么随任务改变？ 数据量和优化配方各起什么作用？ 更高性能需要付出多少成本？	E1规模 + S1/早停 + 最终Q + 计时 两组优化Q：DistilBERT > SVM > BiLSTM。 按各自条件保留性能与成本的权衡。
表征与适配	MultiNLI matched： 配对SVM 0.4990，DistilBERT 0.6580。 原报告指出外部预训练与架构差异并存。	预训练初始化和下游适配 分别贡献什么？ 不能把优势全部归于架构名称。	M2：BANKING77同架构四臂 初始化 × 冻结/解冻，匹配9个配置。 V证据支持预训练与任务适配共同贡献。
长尾与补救	AG News严重倾斜：F1降幅 SVM 77.76点，DistilBERT 12.86点。 加权有收益，但未分离稀缺与类别偏置。	独立标注不足与训练贡献不足 能否分别解释退化？ 增加权重是否能替代增加信息？	E3任务扩展 + S3支持×贡献Q对照 均匀贡献不能补回本组缺失标注； 平均分改善仍可能伴随尾类恶化。
具体错误与线索	已有逐样本预测、待复核错误队列， hypothesis-only诊断提示可用线索。 现象观察尚未构成统一机制验证。	加数据后哪些错误持续或新增？ 线索形式变化能否触发错误？ 如何把总体分数连接到具体失败？	S2同样本轨迹 + S4配对词汇干预 定位错误转移；37对AI审核子集中， SVM对线索替换比DistilBERT更敏感。

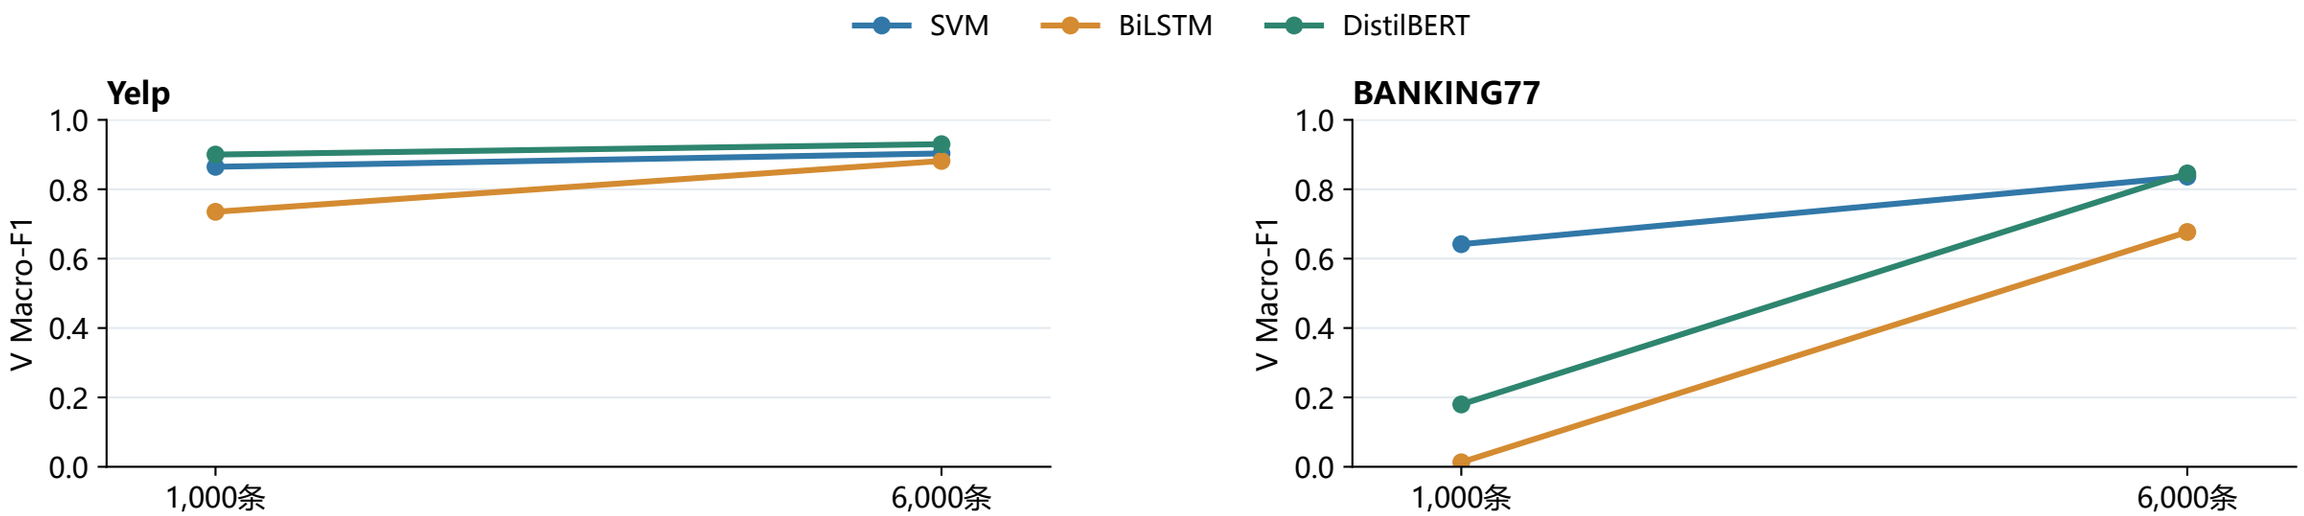
整体论证：任务/分布/成本比较 → 条件性优势与失败 → 可检验假设 → 匹配对照与干预 → 定量/定性解释

原结果按11月6日交接清单验SHA；后续问题是当前的梳理，不倒写为旧阶段已完成的机制验证。

MultiNLI与BANKING77不是同一任务；旧batch1延迟与新批预测均摊耗时不直接拼接。后续11张结果图保持原证据口径。

01 加数据后，模型差距怎样变化?

E1规模对照 | 同任务训练1,000→6,000条；四个任务分别比较，使用各自V主指标。

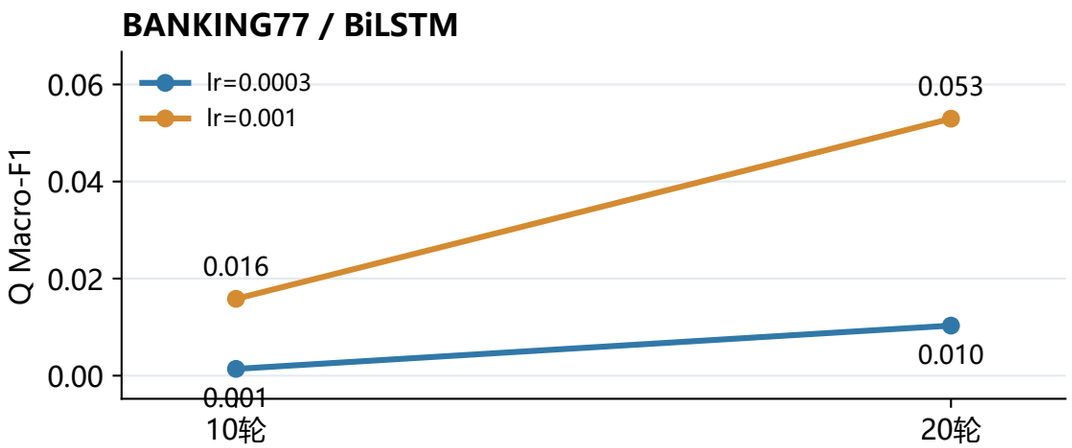


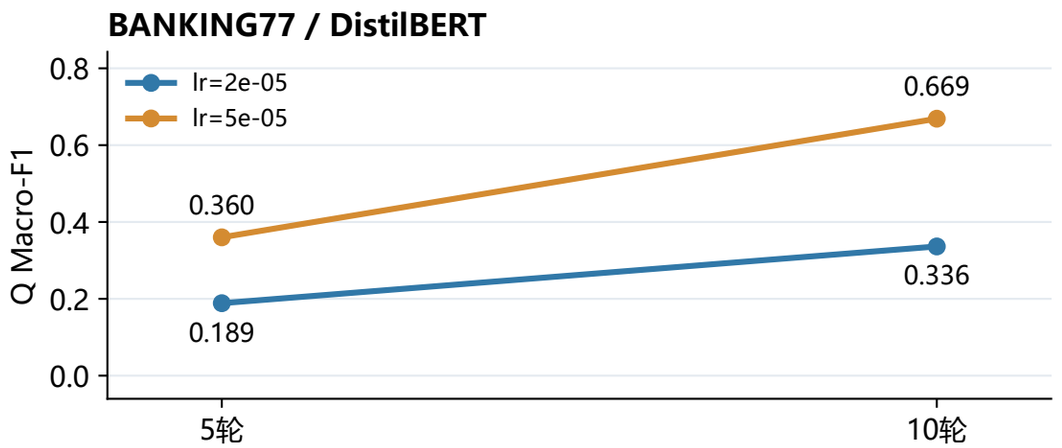
结论 数据规模会改变模型差距；BANKING77的BiLSTM、DistilBERT在6k时明显改善。

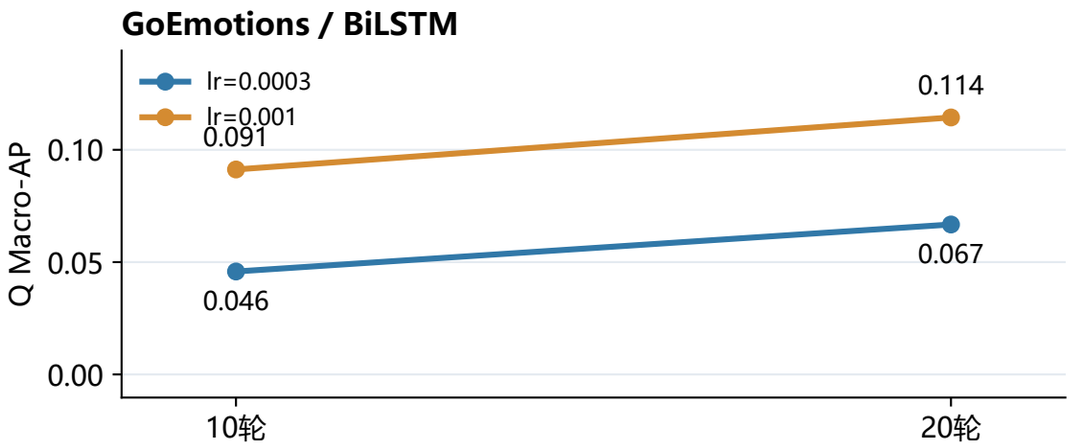
旧固定预算探索：BiLSTM 10轮、DistilBERT 5轮；单配置无误差条。这里不是优化后Q学习曲线。
两个规模点不能定位精确临界样本量；各任务指标不合并排名。

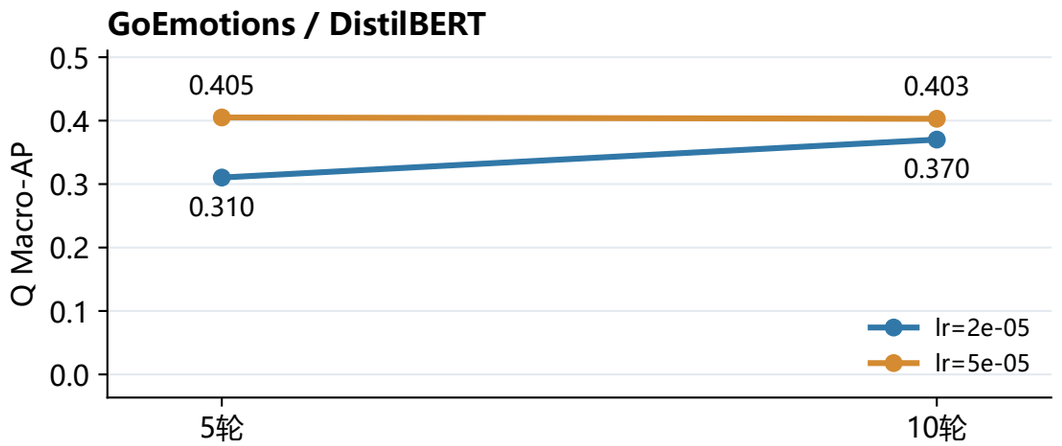
02 早期低分有多少来自优化配方?

S1独立Q | 同任务、同模型，比较两档学习率×两档总预算；共16个固定模型。







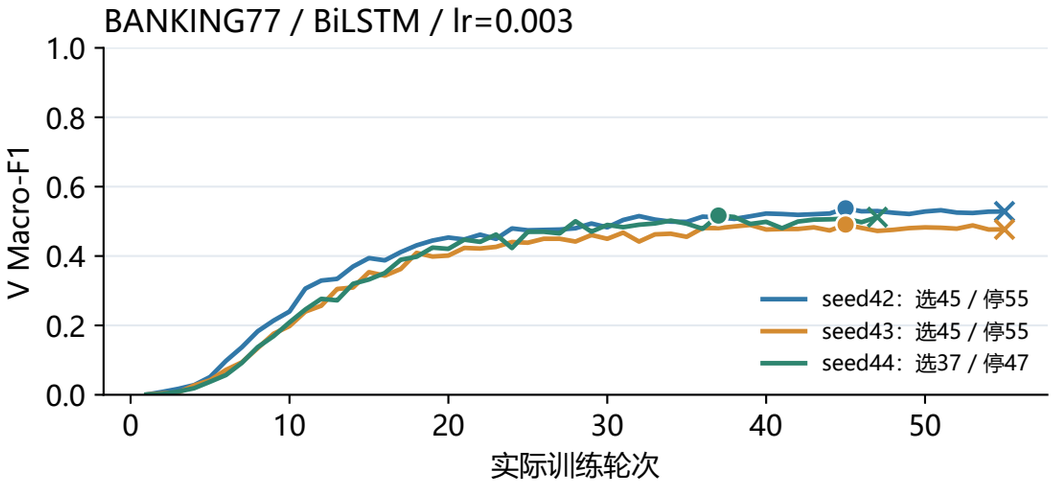


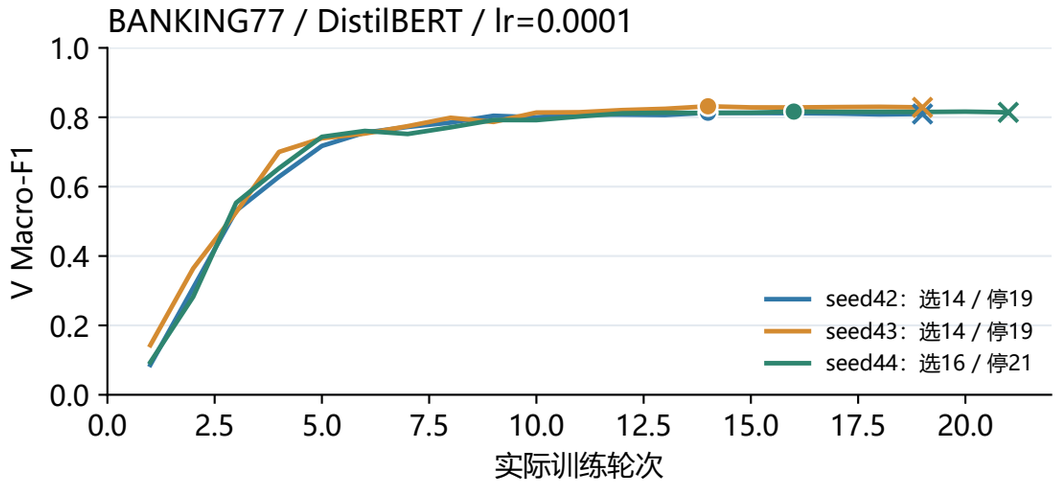
结论 BANKING77 DistilBERT在lr=5e-5时提高30.88点；GoEmotions高学习率下AP基本持平。

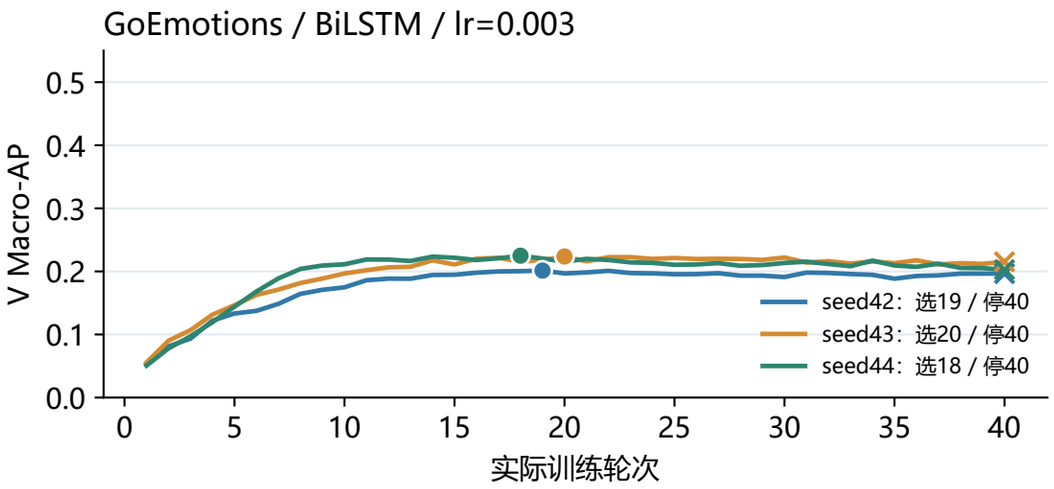
单seed42；预算变化同时改变线性衰减计划，解释为配方/预算效应，不是纯轮数效应。
不同子图y轴范围不同；所有检查点在Q评估前已固定。

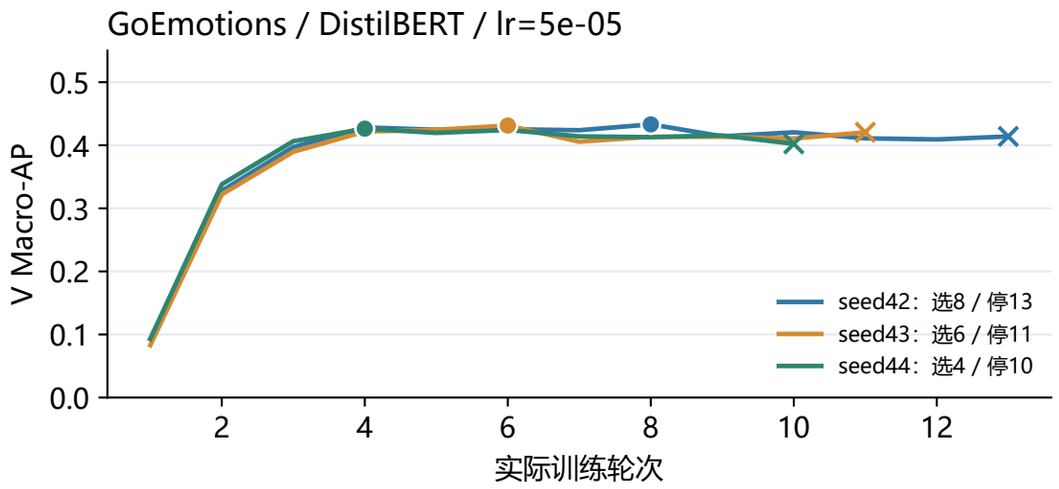
03 最终配方实际训练到哪里才停止?

后续优化轮 | 每个神经模型3个训练种子；实线为逐轮V指标，圆点为选中轮，叉号为停止轮。







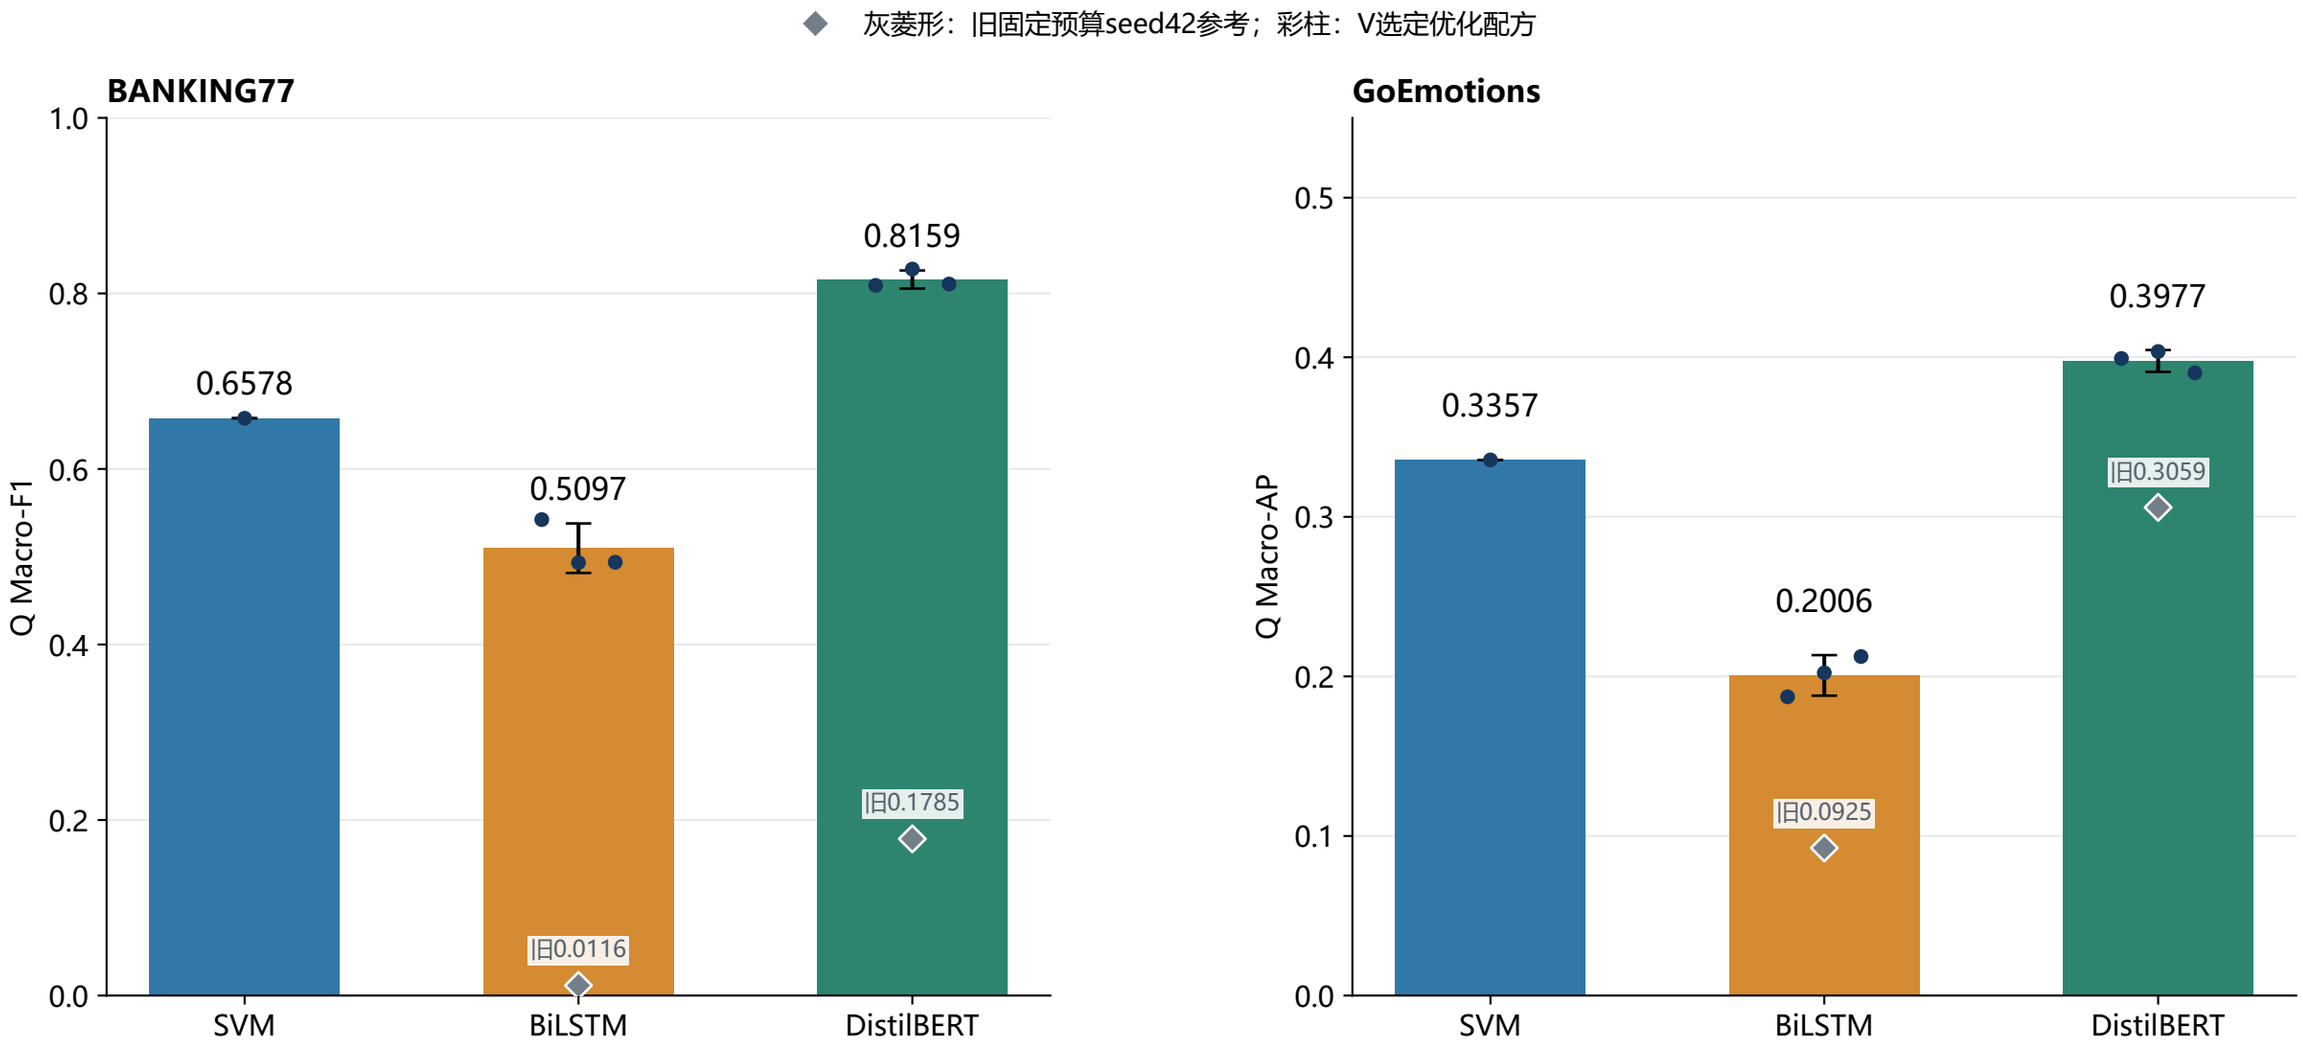


结论 12个最终神经模型均触发patience早停；选中轮次与实际训练终止轮次分别记录。

BANKING77 1k、GoEmotions 6k；仅展示V选定配方的三个种子，未展示全部未选学习率。
早停表示满足既定停止准则，不等于证明全局最优。未用Q逐轮挑选检查点。

04 优化后，正式测试中的模型差距还在吗?

最终模型Q｜BANKING77训练1k、Q 3,079条；GoEmotions训练6k、Q 5,401条。

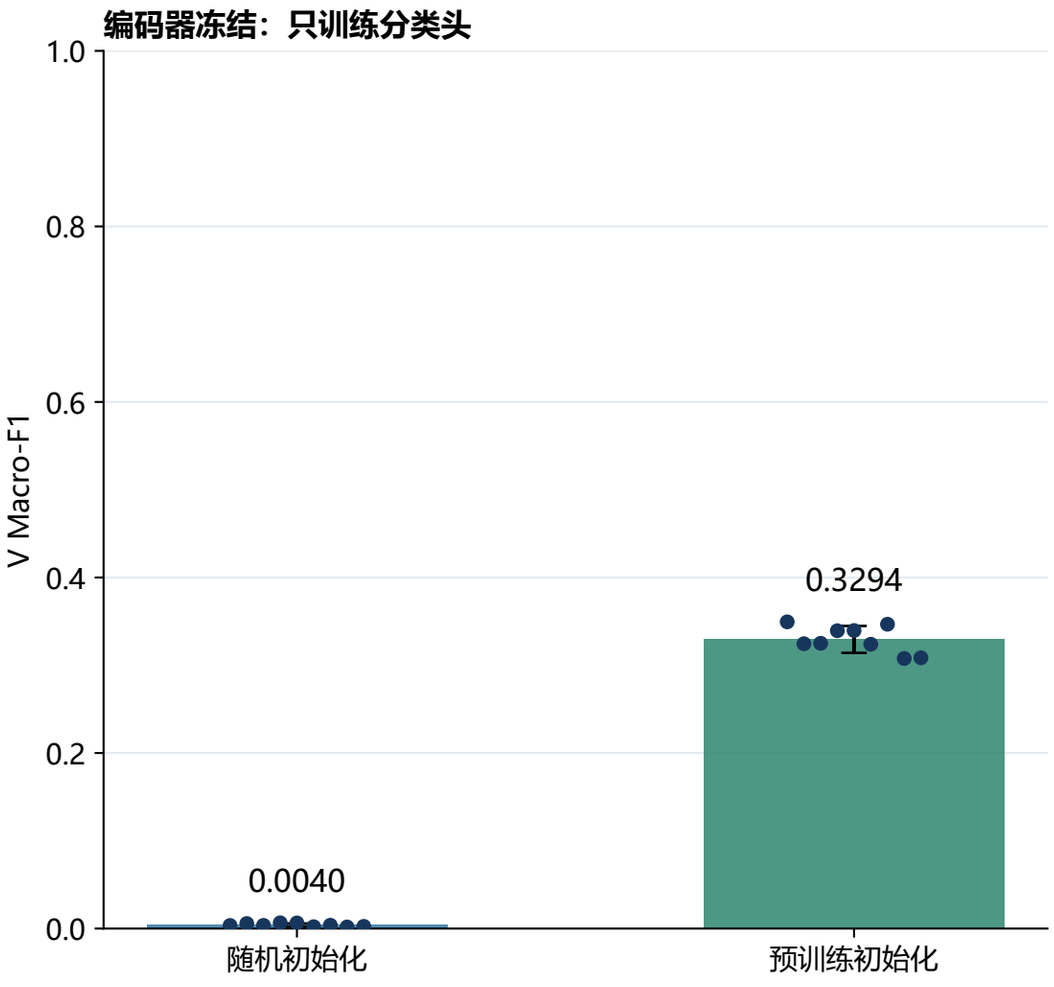


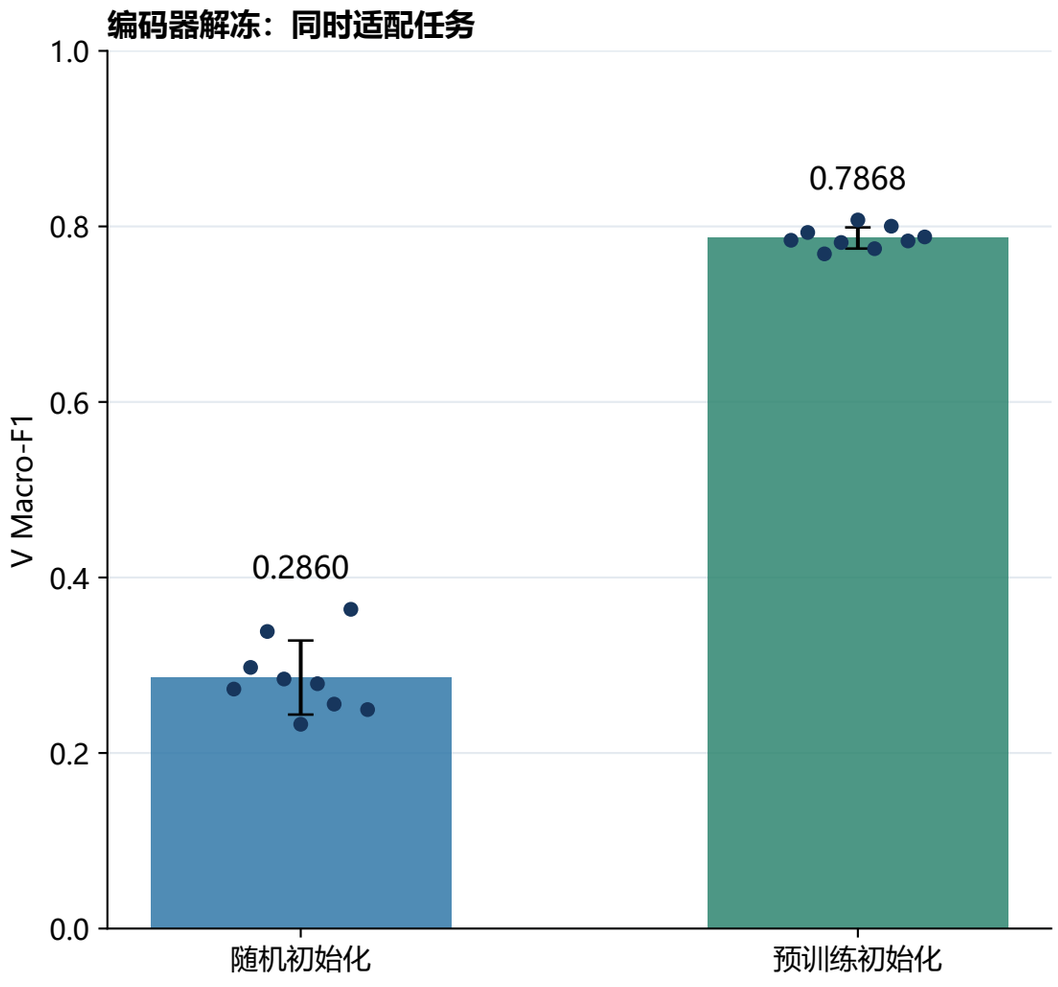
结论 两组已测条件均为DistilBERT > SVM > BiLSTM，三个神经训练种子保持相同排序。

彩柱为均值；神经n=3、误差条为训练种子样本SD，散点为每个种子；SVM确定性单次。SD不是测试置信区间。
灰菱形共4个历史Q参考；新旧配方同时改变学习率/预算/调度，不把差距全归于训练轮数。

05 优势来自预训练，还是下游适配?

M2匹配四臂 | BANKING77 1k；相同DistilBERT架构与分类头初始化，编码器学习率固定2e-5。



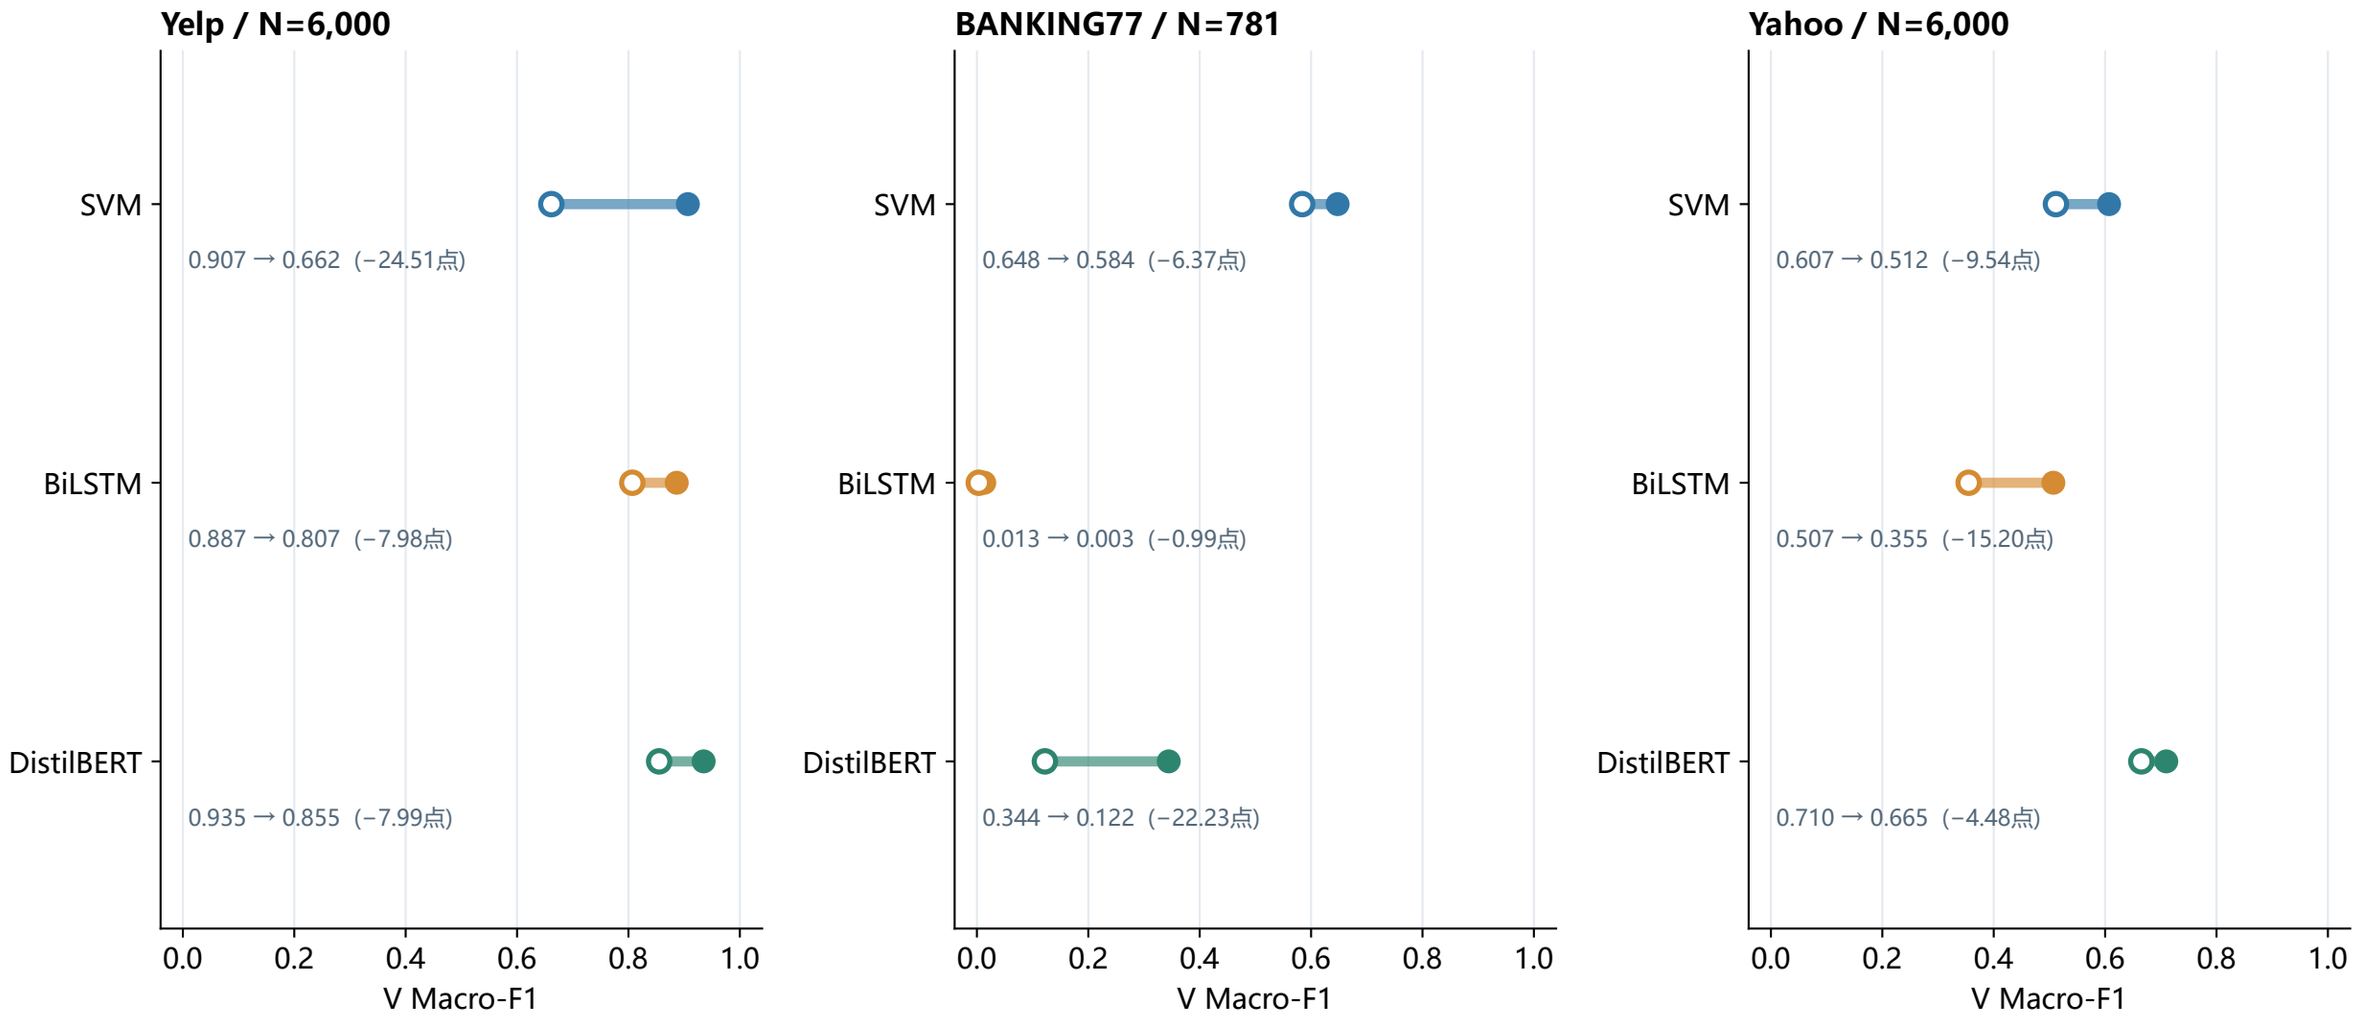


结论 解冻时预训练提高50.08点；预训练后解冻提高45.74点，两个方向均在9/9成对配置中成立。

每臂3个数据抽样×3个训练种子，点为配置、柱为均值、误差条为配置间样本SD。
这是V机制证据，未包含在42个Q模型中；不把9个配置当作9个独立任务。

06 类别倾斜时，哪个模型更容易退化?

E3固定预算探索 | 同任务训练总量与V集不变，比较均衡与倾斜条件；左端为倾斜，右端为均衡。

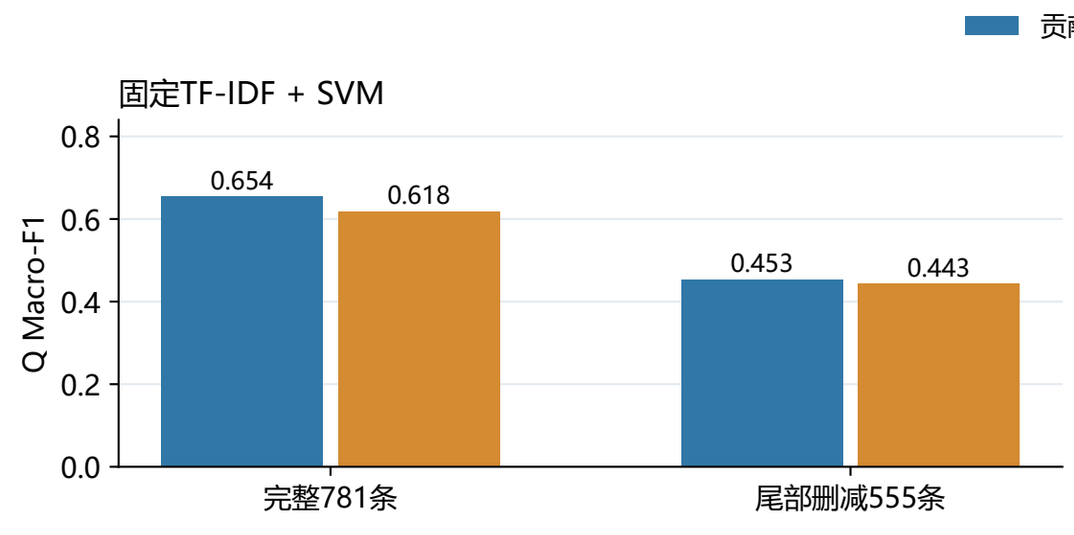


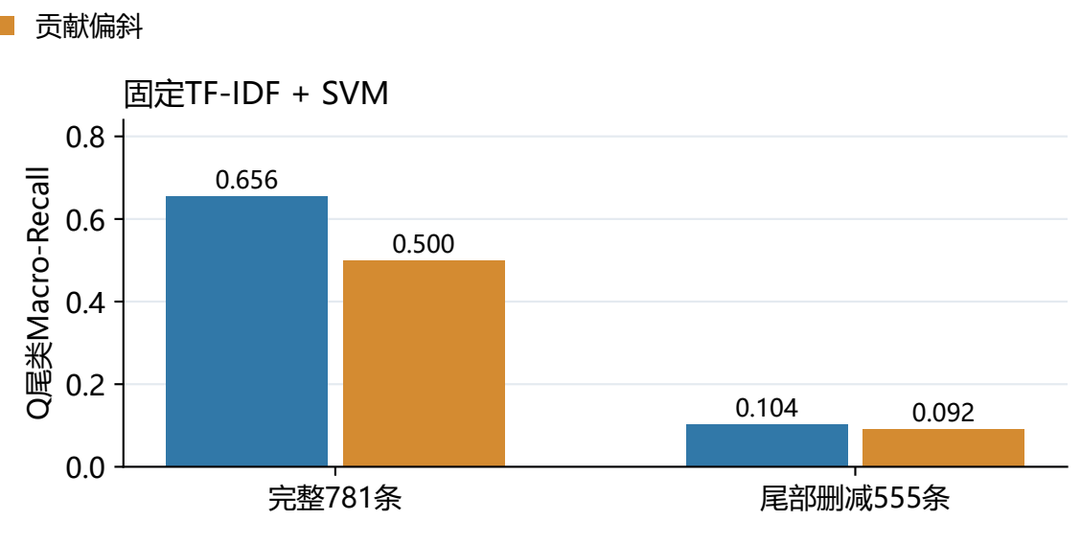
结论 Yelp上SVM退化更大，BANKING77上DistilBERT退化更大；鲁棒性排序随任务变化。

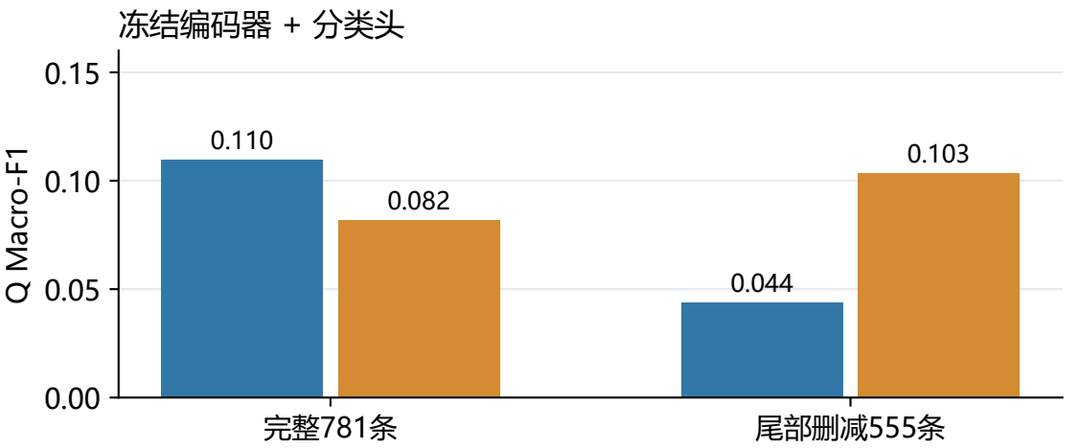
实心为均衡、空心为倾斜；原固定预算V结果，包含优化因素。
BANKING77 BiLSTM均衡F1仅0.0132，小降幅不能称稳健；标注支持和类别贡献尚需S3分开检验。

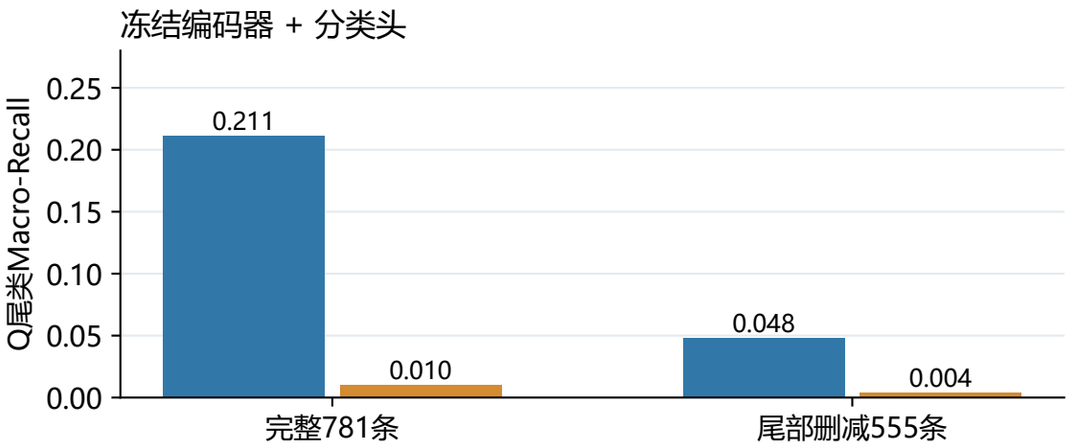
07 补训练权重，能否替代缺失的尾类标注?

S3独立Q | 每种固定表示内，比较支持完整/删减×贡献均匀/偏斜；Q 3,079条。







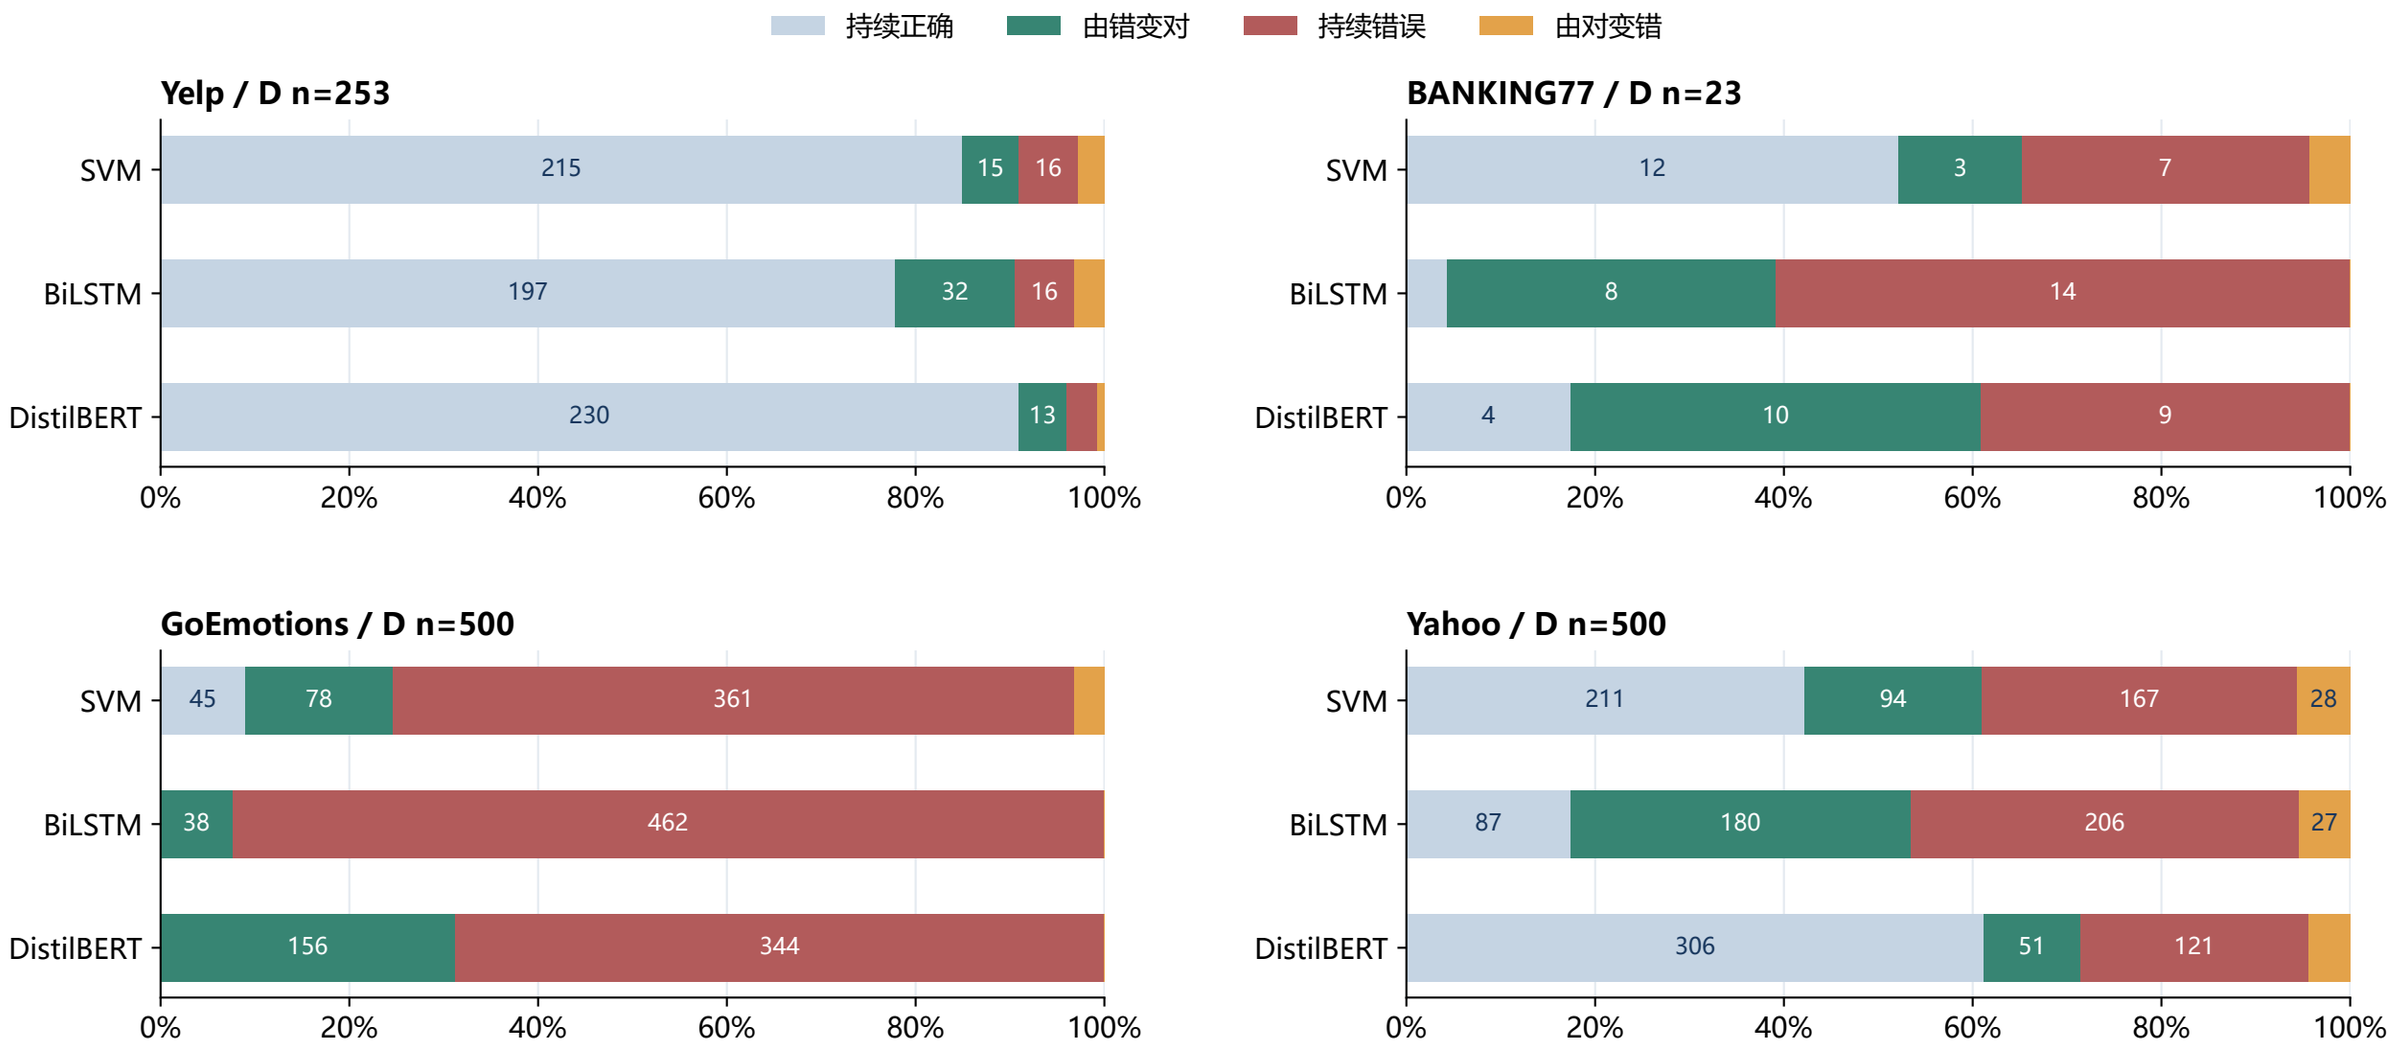


结论 均匀贡献无法补回独立标注；冻结头整体F1提升0.044→0.103时，尾类召回4.8%→0.4%。

SVM固定总权重781，冻结头固定245次更新；尾类集合事先定义，各格单seed。
不同固定表示不作端到端模型排名；整体Macro-F1改善也可能掩盖局部失效。

08 加数据后，究竟纠正了谁、又错了谁?

S2样本轨迹 | 同一批D文本，比较原1k→6k模型；条内数字为样本数，条长为该D集占比。

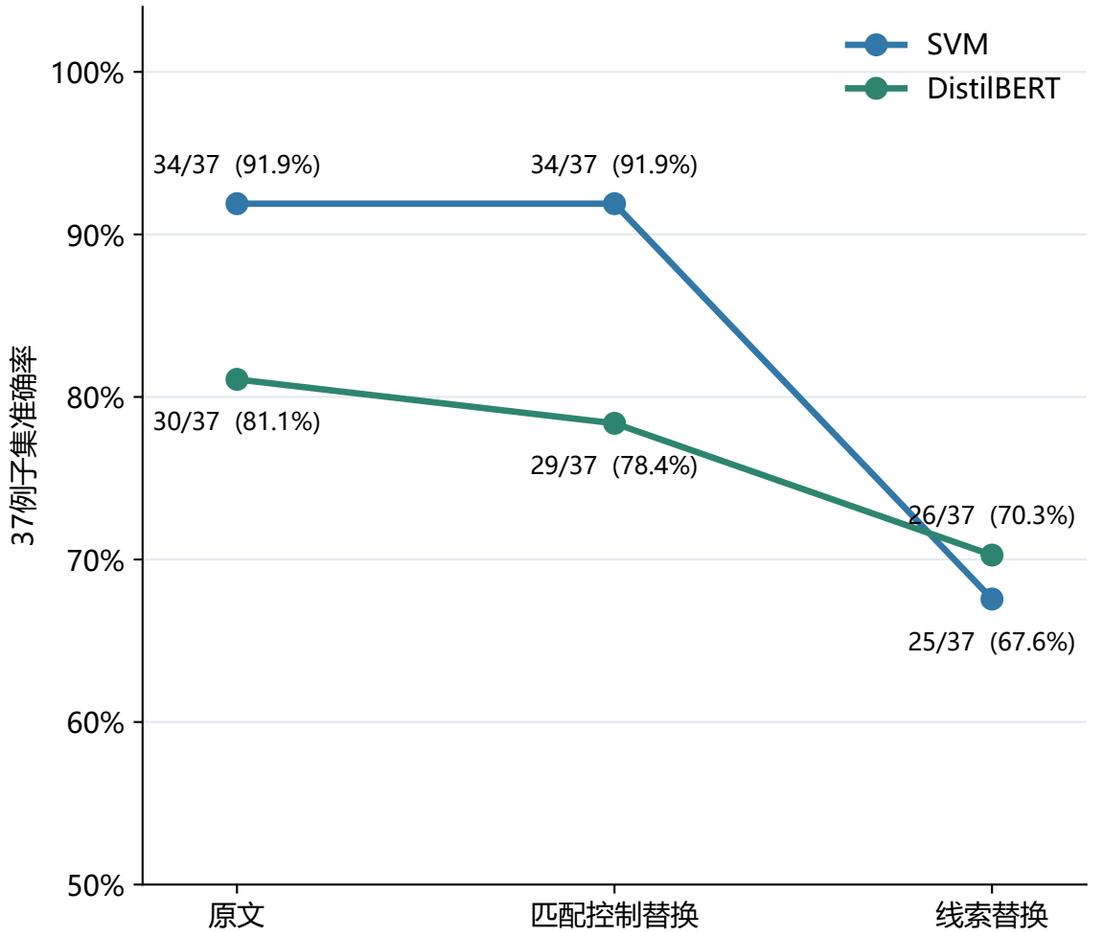


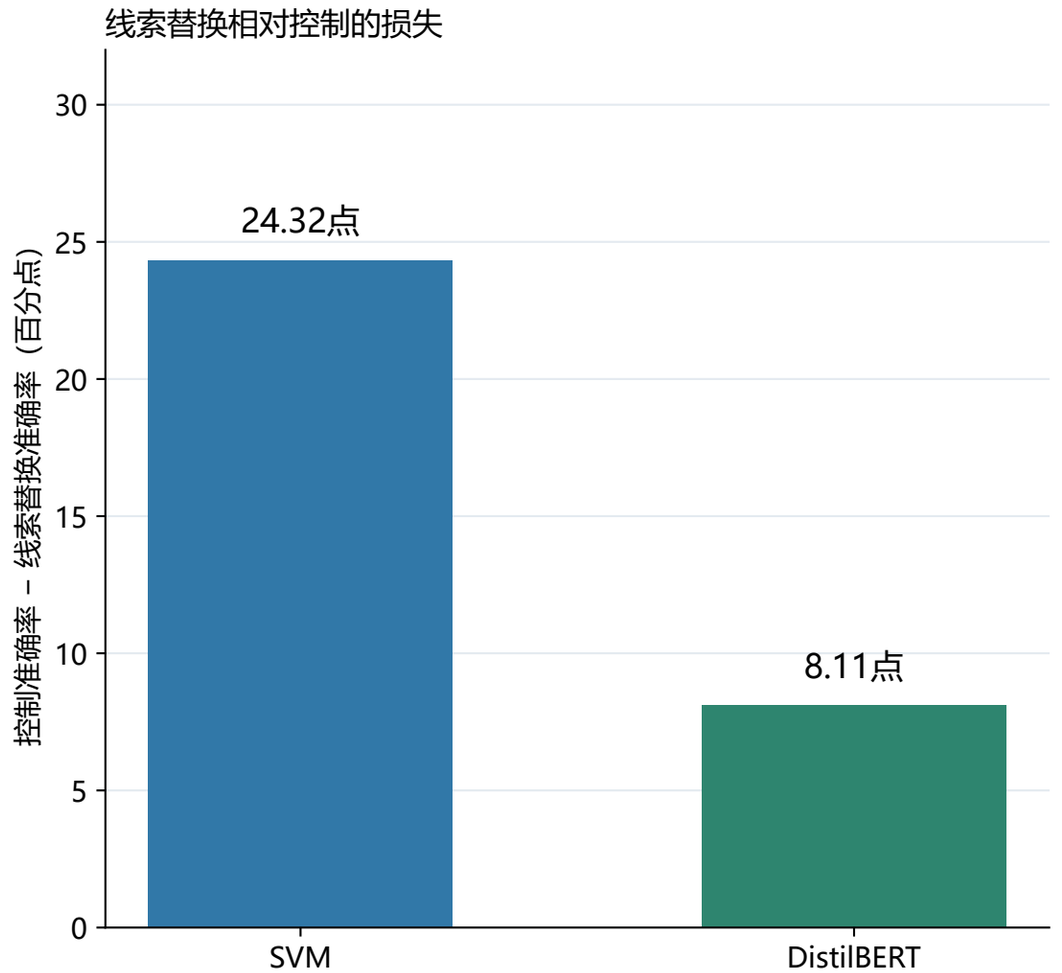
结论 增加数据能纠错，也会引入新错；四任务的DistilBERT都仍有持续错误样本。

旧固定预算检查点；持续错误不等于优化后不可解。BANKING77 D仅23条。
GoEmotions以0阈值完整标签集合判断整条对错，其他任务为单标签；不能跨任务比较“错误率”。

09 原文准确，是否代表表达改变后仍稳定?

S4/M1配对干预 | BANKING77两个固定6k模型；同37个样本比较原文、匹配控制替换和线索替换。





结论 本组线索替换使SVM损失24.32点、DistilBERT损失8.11点；原文排名不能代表扰动稳定性。

37对由Gemini两个表格版本审核，按AI辅助子研究报告；不是双真人独立复核。
这是筛选出的可改写D子集，不代表整个任务的扰动发生率；误差条未作推断。

10 哪些具体错误解释了词汇敏感性?

定性案例 | 同一输入的三臂结果；标签判断依据原业务意图，不用情绪正负替代意图。

M1-013 收款人未收到转账

原文
I just did a money transaction but its not showing they received it

线索替换：transaction → transfer
控制替换：did → made

模型	原文	控制替换	线索替换
SVM	正确	正确	错误
DistilBERT	正确	正确	正确

SVM误判：转账处理中

M1-019 退款未到账

原文
No refund showing in my statement.

线索替换：refund → reimbursement
控制替换：showing → appearing

模型	原文	控制替换	线索替换
SVM	正确	正确	错误
DistilBERT	正确	正确	错误

SVM误判：账单额外收费

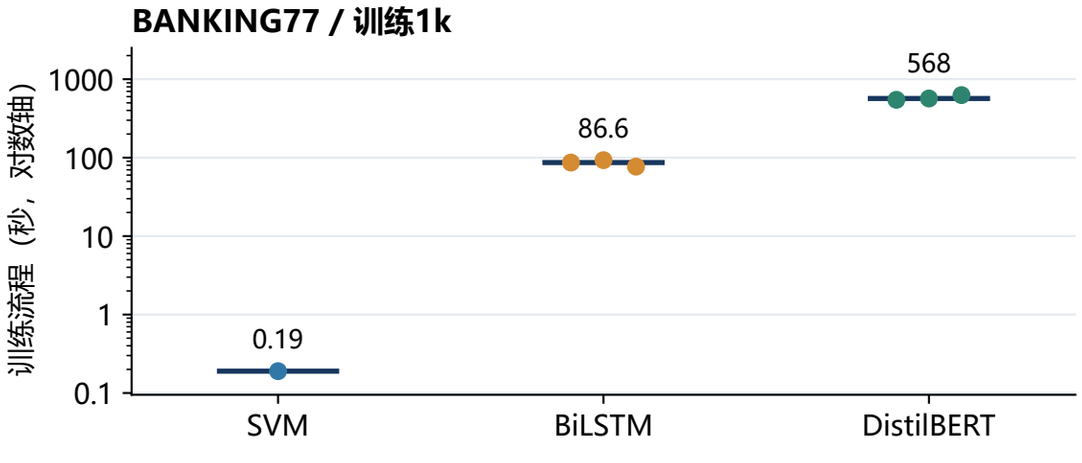
DistilBERT误判：不认识的自动扣款

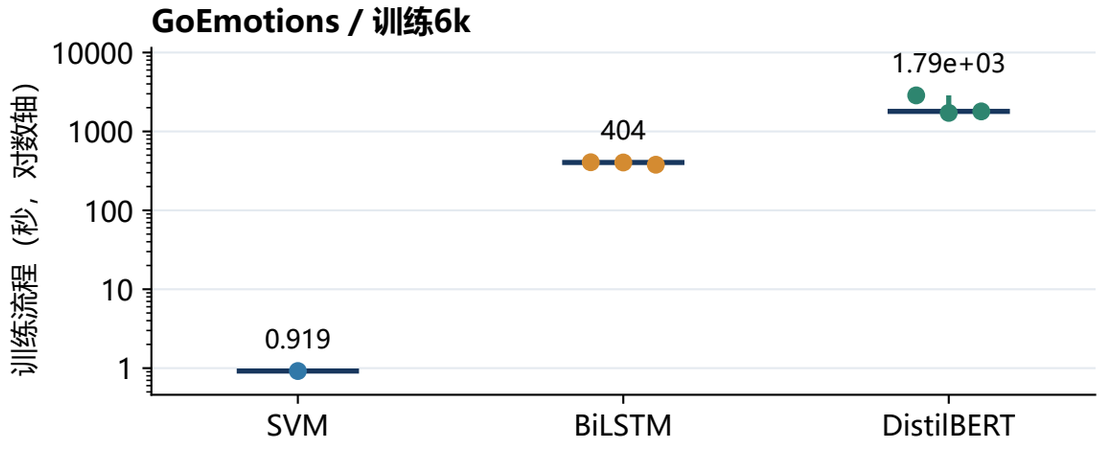
结论 转账案例中DistilBERT保持正确，退款同义替换却令两模型都错：相对稳定不等于完全不敏感。

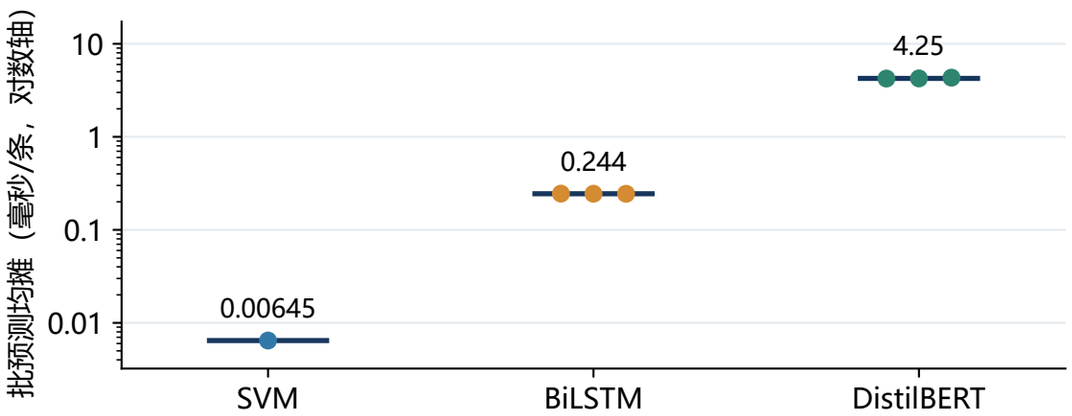
案例M1-013、M1-019来自同一37对AI审核干预集；仅解释失败形式，不估计总体频率。
正确/错误由保存的逐例预测与金标签重建，未重新运行模型。

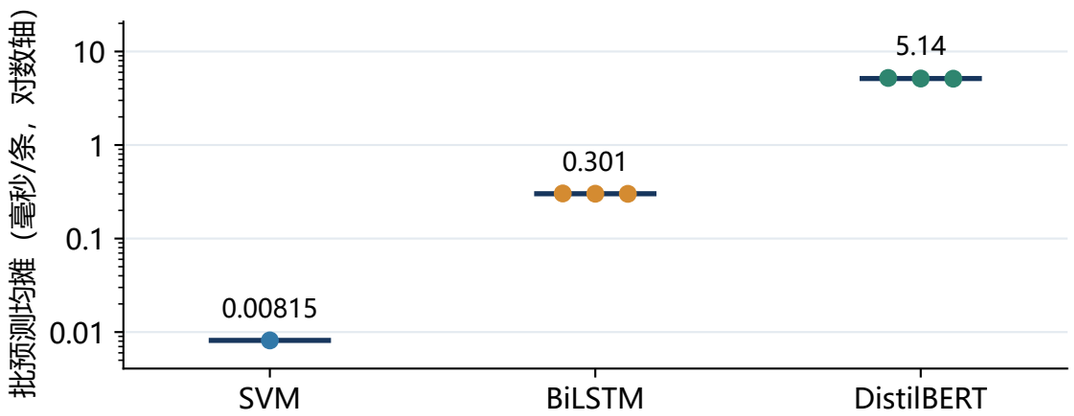
11 取得这些分数，训练与推理分别花多久?

最终14个模型实测 | 相同CPU 8线程；上行训练流程总秒数，下行批预测均摊毫秒/条；均使用对数轴。









结论 本轮SVM成本最低；DistilBERT取得更高Q分数，同时付出更高的训练与批预测成本。

点为各种子，横线为中位数；训练为既有资产下单模型流程，含特征/验证/保存，不含预训练与全网格搜索。
预测不含加载/校验/清理，均摊时间不是在线延迟。共享CPU实测；BANKING77 DistilBERT seed43训练含续跑重建。